

# EPG3343 - Seminario de Estadística III

## Clase 4

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



## 1 Campos Aleatorios

- Estimadores No Paramétricos
- Estimador en base a Modelos Paramétricos
  - Estimación por Máxima Verosimilitud
  - Estimación por Máxima Verosimilitud Restringida
  - Estimación por Mínimos Cuadrados
- Criterios de Elección de Modelos
- Estimación Bajo Anisotropía
  - Anisotropía Geométrica
  - Anisotropía Estratificada

## 1 Campos Aleatorios

- Estimadores No Paramétricos
- Estimador en base a Modelos Paramétricos
  - Estimación por Máxima Verosimilitud
  - Estimación por Máxima Verosimilitud Restringida
  - Estimación por Mínimos Cuadrados
- Criterios de Elección de Modelos
- Estimación Bajo Anisotropía
  - Anisotropía Geométrica
  - Anisotropía Estratificada

# Estimadores No paramétricos

Vimos que:

- El estimador de Matheron (1965) del semivariograma es :

$$\hat{\gamma}(\mathbf{h}) = \frac{1}{2|N(\mathbf{h})|} \sum_{N(\mathbf{h})} [Z(\mathbf{s}_i) - Z(\mathbf{s}_j)]^2$$

# Estimadores No paramétricos

Vimos que:

- El estimador de Matheron (1965) del semivariograma es :

$$\hat{\gamma}(\mathbf{h}) = \frac{1}{2|N(\mathbf{h})|} \sum_{N(\mathbf{h})} [Z(\mathbf{s}_i) - Z(\mathbf{s}_j)]^2$$

- El estimador robusto de Cresie & Hawking (1980):

$$\hat{\gamma}(\mathbf{h}) = \frac{\left( \frac{1}{|N(\mathbf{h})|} \sum_{N(\mathbf{h})} |Z(\mathbf{s}_i) - Z(\mathbf{s}_j)|^{1/2} \right)^4}{0,914 + \frac{0,988}{|N(\mathbf{h})|}}$$

# Estimadores No paramétricos

Vimos que:

- El estimador de Matheron (1965) del semivariograma es :

$$\hat{\gamma}(\mathbf{h}) = \frac{1}{2|N(\mathbf{h})|} \sum_{N(\mathbf{h})} [Z(\mathbf{s}_i) - Z(\mathbf{s}_j)]^2$$

- El estimador robusto de Cresie & Hawking (1980):

$$\hat{\gamma}(\mathbf{h}) = \frac{\left( \frac{1}{|N(\mathbf{h})|} \sum_{N(\mathbf{h})} |Z(\mathbf{s}_i) - Z(\mathbf{s}_j)|^{1/2} \right)^4}{0,914 + \frac{0,988}{|N(\mathbf{h})|}}$$

- Genton (1998) sugiere, basado en un estimador muy robusto de la escala  $Q_{N(h)}$  (Rousseeuw and Croux, 1993), un estimador del variograma como

$$2\hat{\gamma}(\mathbf{h}) = (Q_{N(h)})^2$$

Este estimador del variograma es más robusto que los anteriores.

# Estimadores No paramétricos

Por otro lado un estimador natural de la función de covarianza esta dado por

$$\hat{C}(\mathbf{h}) = \frac{1}{2|N(\mathbf{h})|} \sum_{N(\mathbf{h})} [Z(\mathbf{s}_i) - \bar{Z}][Z(\mathbf{s}_j) - \bar{Z}]; \quad \text{donde } \bar{Z} = n^{-1} \sum_{i=1}^n Z(\mathbf{s}_i).$$

El estimador  $\hat{\gamma}(\mathbf{h})$  es insesgado para  $\gamma(\mathbf{h})$  si  $Z(\mathbf{s})$  es intrínsecamente estacionario, en cambio si la media se estima desde los datos,  $\hat{C}(\mathbf{h})$  es un estimador sesgado para  $C(\mathbf{h})$ , pero el sesgo desaparece cuando  $n \rightarrow \infty$  ya que  $|N(\mathbf{h})|/n \rightarrow 1$ .

# Estimadores No paramétricos

Por otro lado un estimador natural de la función de covarianza esta dado por

$$\hat{C}(\mathbf{h}) = \frac{1}{2|N(\mathbf{h})|} \sum_{N(\mathbf{h})} [Z(\mathbf{s}_i) - \bar{Z}][Z(\mathbf{s}_j) - \bar{Z}]; \quad \text{donde } \bar{Z} = n^{-1} \sum_{i=1}^n Z(\mathbf{s}_i).$$

El estimador  $\hat{\gamma}(\mathbf{h})$  es insesgado para  $\gamma(\mathbf{h})$  si  $Z(\mathbf{s})$  es intrínsecamente estacionario, en cambio si la media se estima desde los datos,  $\hat{C}(\mathbf{h})$  es un estimador sesgado para  $C(\mathbf{h})$ , pero el sesgo desaparece cuando  $n \rightarrow \infty$  ya que  $|N(\mathbf{h})|/n \rightarrow 1$ .

**Obs:** Ninguno de los estimadores anteriores está bien definido. En el caso, de los estimadores del variograma no cumplen con la propiedad de ser condicionalmente definidos negativos. Mientras que el estimador de la función de covarianza no es definida positiva.



Denotemos por  $\theta$  al conjunto paramétrico que definen al modelo espacial.

# Estimador en base a Modelos Paramétricos

Denotemos por  $\theta$  al conjunto paramétrico que definen al modelo espacial.

La estimación de  $\theta$  se puede llevar a cabo:

- Utilizando supuestos distribucionales (log-verosimilitud):  
Máxima Verosimilitud (ML); Máxima Verosimilitud Restringida (REML).

# Estimador en base a Modelos Paramétricos

Denotemos por  $\theta$  al conjunto paramétrico que definen al modelo espacial.

La estimación de  $\theta$  se puede llevar a cabo:

- Utilizando supuestos distribucionales (log-verosimilitud):  
Máxima Verosimilitud (ML); Máxima Verosimilitud Restringida (REML).
- Utilizando las técnicas de mínimos cuadrados no lineales.

# Estimador en base a Modelos Paramétricos

Denotemos por  $\theta$  al conjunto paramétrico que definen al modelo espacial.

La estimación de  $\theta$  se puede llevar a cabo:

- Utilizando supuestos distribucionales (log-verosimilitud):  
Máxima Verosimilitud (ML); Máxima Verosimilitud Restringida (REML).
- Utilizando las técnicas de mínimos cuadrados no lineales.
- A partir de pseudo-datos que ayuden a simplificar el problema:  
Ecuaciones de Estimación Generalizada (GEE); Composición de Verosimilitudes (CL). (Schabenberger and Gotway, 2005)  
Ejemplo de pseudo-dato,  $T_{ij} = Z(\mathbf{s}_i) - Z(\mathbf{s}_j)$ .

Suponga que la variable  $Z$  ha sido observada en  $n$  sitios, tal que

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}(\boldsymbol{\theta}))$$

$$\boldsymbol{\theta} = (\tau^2, \sigma^2, \phi), \quad \dim(\boldsymbol{\theta}) \ll n.$$

Suponga que la variable  $Z$  ha sido observada en  $n$  sitios, tal que

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}(\boldsymbol{\theta}))$$

$$\boldsymbol{\theta} = (\tau^2, \sigma^2, \phi), \quad \dim(\boldsymbol{\theta}) \ll n.$$

$$l(\boldsymbol{\mu}, \boldsymbol{\theta}) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln |\boldsymbol{\Sigma}(\boldsymbol{\theta})| - \frac{1}{2} (\mathbf{Z} - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1}(\boldsymbol{\theta}) (\mathbf{Z} - \boldsymbol{\mu})$$

# Máxima Verosimilitud

Suponga que la variable  $Z$  ha sido observada en  $n$  sitios, tal que

$$\mathbf{Z} = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}(\boldsymbol{\theta}))$$

$$\boldsymbol{\theta} = (\tau^2, \sigma^2, \phi), \quad \dim(\boldsymbol{\theta}) \ll n.$$

$$l(\boldsymbol{\mu}, \boldsymbol{\theta}) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln |\boldsymbol{\Sigma}(\boldsymbol{\theta})| - \frac{1}{2} (\mathbf{Z} - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1}(\boldsymbol{\theta}) (\mathbf{Z} - \boldsymbol{\mu})$$

Lamentablemente  $\hat{\boldsymbol{\mu}}$  y  $\hat{\boldsymbol{\theta}}$  en la mayoría de los casos no tiene forma cerrada y, por lo tanto, se obtienen resolviendo el sistema no lineal:

$$\nabla l(\boldsymbol{\mu}, \boldsymbol{\theta}) = \mathbf{0}$$

mediante algoritmos numéricos como Newton-Raphson.

Para el caso media lineal,  $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$ , donde  $\mathbf{X} = \mathbf{X}(\mathbf{s})$ :

$$\hat{\boldsymbol{\beta}}_{ML} = \left( \mathbf{X}^\top \boldsymbol{\Sigma}^{-1}(\hat{\boldsymbol{\theta}}_{ML}) \mathbf{X} \right)^{-1} \mathbf{X}^\top \boldsymbol{\Sigma}^{-1}(\hat{\boldsymbol{\theta}}_{ML}) \mathbf{Z}$$

y

$$\hat{\boldsymbol{\theta}}_{ML} = \hat{\boldsymbol{\theta}}_{ML}(\hat{\boldsymbol{\beta}})$$

Esto significa que se debe realizar un proceso iterativo.



# Máxima Verosimilitud Restringida

**Definición:** Sea  $\mathbf{K}$  una matriz de dimensión  $(n - k) \times n$  tal que

$$\mathbb{E}[\mathbf{K}\mathbf{Z}(s)] = \mathbf{0}.$$

El método de estimación REML consiste en estimar  $\boldsymbol{\theta}$  maximizando la log-verosimilitud de  $\mathbf{K}\mathbf{Z}(s)$ .

# Máxima Verosimilitud Restringida

**Definición:** Sea  $\mathbf{K}$  una matriz de dimensión  $(n - k) \times n$  tal que

$$\mathbb{E}[\mathbf{K}\mathbf{Z}(s)] = \mathbf{0}.$$

El método de estimación REML consiste en estimar  $\boldsymbol{\theta}$  maximizando la log-verosimilitud de  $\mathbf{K}\mathbf{Z}(s)$ .

- En la literatura la matriz  $\mathbf{K}$  es denominada matriz de contraste de errores.
- Notar que  $\mathbb{V}[\mathbf{K}\mathbf{Z}(s)] = \mathbf{K}\boldsymbol{\Sigma}\mathbf{K}^\top$ .
- La matriz  $\mathbf{K}$  no es única.
- Afortunadamente, esto no importa para la estimación de parámetros ni inferencia Harville (1974).

Note que

$$l(\boldsymbol{\theta}) = -\frac{n-k}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{K}\boldsymbol{\Sigma}(\boldsymbol{\theta})\mathbf{K}^\top| - \frac{1}{2} \mathbf{Z}^\top \mathbf{K}^\top (\mathbf{K}\boldsymbol{\Sigma}(\boldsymbol{\theta})\mathbf{K}^\top)^{-1} \mathbf{K} \mathbf{Z}$$

Claramente no aparece  $\boldsymbol{\beta}$  en la log-verosimilitud de  $\mathbf{K}\mathbf{Z}$ . Una vez obtenido  $\hat{\boldsymbol{\theta}}_{REML}$ , se tiene que

$$\hat{\boldsymbol{\beta}}_{REML} = \left( \mathbf{X}^\top \boldsymbol{\Sigma}^{-1}(\hat{\boldsymbol{\theta}}_{REML}) \mathbf{X} \right)^{-1} \mathbf{X}^\top \boldsymbol{\Sigma}^{-1}(\hat{\boldsymbol{\theta}}_{REML}) \mathbf{Z}$$

**Resultado:** Si  $\Sigma(\theta)$  es definida positiva, entonces

$$\mathbf{K}^\top \left( \mathbf{K} \Sigma(\theta) \mathbf{K}^\top \right)^{-1} \mathbf{K} = \Sigma^{-1}(\theta) - \Sigma^{-1}(\theta) \mathbf{X} \Omega(\theta) \mathbf{X}^\top \Sigma^{-1}(\theta)$$

donde

$$\Omega(\theta) = \left( \mathbf{X}^\top \Sigma^{-1}(\theta) \mathbf{X} \right)^{-1}$$

Es decir, no depende de la matriz  $\mathbf{K}$ .

Ejemplo de matrices de contraste de errores en procesos espaciales ver Harville (1974, 1977).

$$\textcircled{1} \quad K^\top K = I - X (X^\top X)^{-1} X^\top$$

$$\textcircled{2} \quad K^\top K = I.$$

**Observación:** La estimación REML es usada sólo en el caso que la función de media es una estructura lineal, en otro caso no es claro como construir la matriz  $K$ .

# Mínimos Cuadrados

Considere:

$\hat{\gamma}(\cdot)$	El variograma empirico
$\gamma(\cdot, \boldsymbol{\theta})$	El variograma teórico

Suponga que

$$\hat{\gamma}(\mathbf{h}) = \gamma(\mathbf{h}, \boldsymbol{\theta}) + e(\mathbf{h})$$

Los mínimos cuadrados no lineales consisten en minimizar:

# Mínimos Cuadrados

Considere:

$\hat{\gamma}(\cdot)$	El variograma empírico
$\gamma(\cdot, \boldsymbol{\theta})$	El variograma teórico

Suponga que

$$\hat{\gamma}(\mathbf{h}) = \gamma(\mathbf{h}, \boldsymbol{\theta}) + e(\mathbf{h})$$

Los mínimos cuadrados no lineales consisten en minimizar:

- Caso  $\mathbb{V}[e(\mathbf{h})] \propto \mathbf{I}$ : (OLS)

$$\sum_{i=1}^K (\hat{\gamma}(h_i) - \gamma(h_i, \boldsymbol{\theta}))^2 \quad \equiv \quad (\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))^\top (\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))$$

# Mínimos Cuadrados

Considere:

$\hat{\gamma}(\cdot)$	El variograma empírico
$\gamma(\cdot, \boldsymbol{\theta})$	El variograma teórico

Suponga que

$$\hat{\gamma}(\mathbf{h}) = \gamma(\mathbf{h}, \boldsymbol{\theta}) + e(\mathbf{h})$$

Los mínimos cuadrados no lineales consisten en minimizar:

- Caso  $\mathbb{V}[e(\mathbf{h})] \propto \mathbf{I}$ : (OLS)

$$\sum_{i=1}^K (\hat{\gamma}(h_i) - \gamma(h_i, \boldsymbol{\theta}))^2 \quad \equiv \quad (\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))^\top (\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))$$

- Caso  $\mathbb{V}[e(\mathbf{h})] = \mathbf{R}(\boldsymbol{\theta})$ : (GLS)

$$(\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))^\top \mathbf{R}^{-1}(\boldsymbol{\theta}) (\hat{\boldsymbol{\gamma}}(\mathbf{h}) - \boldsymbol{\gamma}(\mathbf{h}, \boldsymbol{\theta}))$$



# Mínimos Cuadrados

- Caso  $\mathbb{V}[e(\mathbf{h})] = \mathbf{W}(\boldsymbol{\theta})$  una matriz diagonal: (WLS)

$$(\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))^\top \mathbf{W}^{-1}(\boldsymbol{\theta}) (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))$$

En este caso,

$$(\mathbf{W}(\boldsymbol{\theta}))_{ii} \approx \frac{2\gamma(\mathbf{h}_i, \boldsymbol{\theta})^2}{|N(\mathbf{h}_i)|}$$

Por lo tanto, hay que minimizar

$$\begin{aligned} (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))^\top \mathbf{W}^{-1}(\boldsymbol{\theta}) (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta})) = \\ \sum_{i=1}^K \frac{|N(\mathbf{h}_i)|}{2\gamma(\mathbf{h}_i, \boldsymbol{\theta})^2} (\hat{\gamma}(\mathbf{h}_i) - \gamma(\mathbf{h}_i, \boldsymbol{\theta}))^2 \end{aligned}$$

# Mínimos Cuadrados

- Caso  $\mathbb{V}[e(\mathbf{h})] = \mathbf{W}(\boldsymbol{\theta})$  una matriz diagonal: (WLS)

$$(\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))^\top \mathbf{W}^{-1}(\boldsymbol{\theta}) (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))$$

En este caso,

$$(\mathbf{W}(\boldsymbol{\theta}))_{ii} \approx \frac{2\gamma(\mathbf{h}_i, \boldsymbol{\theta})^2}{|N(\mathbf{h}_i)|}$$

Por lo tanto, hay que minimizar

$$\begin{aligned} & (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta}))^\top \mathbf{W}^{-1}(\boldsymbol{\theta}) (\hat{\gamma}(\mathbf{h}) - \gamma(\mathbf{h}, \boldsymbol{\theta})) = \\ & \sum_{i=1}^K \frac{|N(\mathbf{h}_i)|}{2\gamma(\mathbf{h}_i, \boldsymbol{\theta})^2} (\hat{\gamma}(\mathbf{h}_i) - \gamma(\mathbf{h}_i, \boldsymbol{\theta}))^2 \end{aligned}$$

**Obs.:** Stain (2012) sugiere que no es adecuado tratar de ajustar el modelo teórico al variograma empírico.

# Criterios de Elección de Modelos

Webster & Mc Bratney (1989) expendieron las ideas de Akaike (1974) para modelos espaciales:

$$AIC(\boldsymbol{\theta}) = cte + k \ln(RSS(\boldsymbol{\theta})) + 2param \quad (NLS)$$

$$AIC(\boldsymbol{\theta}) = l_R(\boldsymbol{\theta}) + 2param \quad (REML)$$

donde,

- $RSS(\boldsymbol{\theta})$  es la suma de cuadrados residuales.
- $l_R(\boldsymbol{\theta})$  es la log-verosimilitud restringida.

# Criterios de Elección de Modelos

Webster & Mc Bratney (1989) expendieron las ideas de Akaike (1974) para modelos espaciales:

$$AIC(\boldsymbol{\theta}) = cte + k \ln(RSS(\boldsymbol{\theta})) + 2param \quad (NLS)$$

$$AIC(\boldsymbol{\theta}) = l_R(\theta) + 2param \quad (REML)$$

donde,

- $RSS(\theta)$  es la suma de cuadrados residuales.
- $l_R(\theta)$  es la log-verosimilitud restringida.

El valor de la constante no es relevante dado que se debe escoger el modelo con menor AIC

# Nociones de Anisotropía

Asumir Isotropía conlleva a suponer que la dependencia espacial es igual en todas las direcciones, pero esto no tiene porque ser así.

Asumir Isotropía conlleva a suponer que la dependencia espacial es igual en todas las direcciones, pero esto no tiene porque ser así.

**Definición:** Para una dirección  $\vec{e} \in \mathbb{R}^d$  tal que  $\|\vec{e}\| = 1$ , el variograma de un cmapo aleatorio intrinsecamente estacionario en la dirección  $\vec{e}$  se define como:

$$2\gamma_{\vec{e}}(h) = \mathbb{V} [X(\mathbf{s} + h\vec{e}) - X(\mathbf{s})], \quad h \in \mathbb{R}$$

# Nociones de Anisotropía

Asumir Isotropía conlleva a suponer que la dependencia espacial es igual en todas las direcciones, pero esto no tiene porque ser así.

**Definición:** Para una dirección  $\vec{e} \in \mathbb{R}^d$  tal que  $\|\vec{e}\| = 1$ , el variograma de un campo aleatorio intrínsecamente estacionario en la dirección  $\vec{e}$  se define como:

$$2\gamma_{\vec{e}}(h) = \mathbb{V} [X(\mathbf{s} + h\vec{e}) - X(\mathbf{s})], \quad h \in \mathbb{R}$$

**Definición:** Diremos que el proceso (el variograma) es Anisotrópico si existen al menos dos direcciones en las cuales los variogramas direccionales son diferentes.

Distinguiremos entre dos tipos de Anisotropía:



Distinguiremos entre dos tipos de Anisotropía:

- **Anisotropía Geométrica:** Corresponde a una deformación lineal de un modelo Isotrópico.

Distinguiremos entre dos tipos de Anisotropía:

- **Anisotropía Geométrica:** Corresponde a una deformación lineal de un modelo Isotrópico.
- **Anisotropía Zonal o Estratificada:** Corresponde a un variograma anidado sobre varios subespacios de  $\mathbb{R}^d$

El variograma  $2\gamma(\cdot)$  exhibe anisotropía geométrica si resulta ser la deformación lineal de un variograma isotrópico  $2\gamma_0(\cdot)$

$$\gamma(\mathbf{h}) = \gamma_0(\|\mathbf{A}\mathbf{h}\|) \quad \Longleftrightarrow \quad \gamma(\mathbf{h}) = \gamma_0(\sqrt{\mathbf{h}^\top \mathbf{A}^\top \mathbf{A} \mathbf{h}})$$

# Anisotropía Geométrica

El variograma  $2\gamma(\cdot)$  exhibe anisotropía geométrica si resulta ser la deformación lineal de un variograma isotrópico  $2\gamma_0(\cdot)$

$$\gamma(\mathbf{h}) = \gamma_0(\|\mathbf{A}\mathbf{h}\|) \quad \Longleftrightarrow \quad \gamma(\mathbf{h}) = \gamma_0(\sqrt{\mathbf{h}^\top \mathbf{A}^\top \mathbf{A} \mathbf{h}})$$

**Obs:** Este tipo de variograma tiene la misma meseta (Sill) en todas las direcciones, pero con rangos (o rangos prácticos) que varían de acuerdo a la dirección.

# Anisotropía Geométrica

El variograma  $2\gamma(\cdot)$  exhibe anisotropía geométrica si resulta ser la deformación lineal de un variograma isotrópico  $2\gamma_0(\cdot)$

$$\gamma(\mathbf{h}) = \gamma_0(\|\mathbf{A}\mathbf{h}\|) \quad \Longleftrightarrow \quad \gamma(\mathbf{h}) = \gamma_0(\sqrt{\mathbf{h}^\top \mathbf{A}^\top \mathbf{A} \mathbf{h}})$$

**Obs:** Este tipo de variograma tiene la misma meseta (Sill) en todas las direcciones, pero con rangos (o rangos prácticos) que varían de acuerdo a la dirección.

**Caso Particular para  $d = 2$ :** Si  $\mathbf{A}$  es una rotación en un ángulo  $\varphi$  alrededor del origen seguida de una dilatación por un factor  $0 \leq e \leq 1$  con respecto al eje  $Y$ , entonces el conjunto de los rangos forma una elipse con excentricidad  $e$  en una nueva base.

- En la práctica se estiman los variogramas en 4 direcciones principales ( $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  y  $135^\circ$ )

- En la práctica se estiman los variogramas en 4 direcciones principales ( $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  y  $135^\circ$ )
- Se determinan los rangos para cada dirección.

- En la práctica se estiman los variogramas en 4 direcciones principales ( $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  y  $135^\circ$ )
- Se determinan los rangos para cada dirección.
- Luego se construye el gráfico direccional de los rangos para decidir si hay anisotropía geométrica presente o no.



# Anisotropía Estratificada

Se dice que un variograma posee anisotropía zonal si después de un cambio de coordenadas el variograma depende sólo de ciertas coordenadas de  $\mathbf{h}$ .

# Anisotropía Estratificada

Se dice que un variograma posee anisotropía zonal si después de un cambio de coordenadas el variograma depende sólo de ciertas coordenadas de  $\mathbf{h}$ .

Por ejemplo, si  $\mathbb{R}^d = E_1 \oplus E_2$ , donde  $\dim(E_i) = d_i$ ,  $i = 1, 2$  y  $d_1 + d_2 = d$ . Sea  $2\gamma_0$  un variograma isotrópico sobre  $\mathbb{R}^d$ . Si

$$\gamma(\mathbf{h}) = \gamma_0(\mathbf{h}_1), \quad \mathbf{h} = \mathbf{h}_1 + \mathbf{h}_2, \quad \mathbf{h}_i \in E_i, i = 1, 2.$$

Entonces  $2\gamma$  es un variograma estratificado.

Además el Sill de  $\gamma$  será dependiente de la dirección.

# Anisotropía Estratificada

Se dice que un variograma posee anisotropía zonal si después de un cambio de coordenadas el variograma depende sólo de ciertas coordenadas de  $\mathbf{h}$ .

Por ejemplo, si  $\mathbb{R}^d = E_1 \oplus E_2$ , donde  $\dim(E_i) = d_i$ ,  $i = 1, 2$  y  $d_1 + d_2 = d$ . Sea  $2\gamma_0$  un variograma isotrópico sobre  $\mathbb{R}^d$ . Si

$$\gamma(\mathbf{h}) = \gamma_0(\mathbf{h}_1), \quad \mathbf{h} = \mathbf{h}_1 + \mathbf{h}_2, \quad \mathbf{h}_i \in E_i, i = 1, 2.$$

Entonces  $2\gamma$  es un variograma estratificado.

Además el Sill de  $\gamma$  será dependiente de la dirección.

Chiles & Delfines (2009) proponen considerar modelos separados:

$$\begin{aligned}\gamma(\mathbf{h}) &= \gamma_0(h_1) + \gamma_1(h_2) \quad \text{en } \mathbb{R}^2 \\ \gamma(\mathbf{h}) &= \gamma_1(h_1, h_2) + \gamma_2(h_3) \quad \text{en } \mathbb{R}^3\end{aligned}$$

- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.
- Rousseeuw, P. J., Croux, C., (1993). Alternatives of the median absolute deviation. *Journal of American Statistics Association*, **88**, 1273–1283.

¿Alguna Consulta?