

EPG3343 - Seminario de Estadística III

Clase 5

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



- 1 Introducción a la Predicción Espacial (Kriging)
 - Nociones de Esperanza Condicional
 - Nociones de la Distribución Normal Multivariada

- 2 Kriging Lineales
 - Kriging Simple
 - Kriging Ordinario
 - Kriging Universal

- 1 Introducción a la Predicción Espacial (Kriging)
 - Nociones de Esperanza Condicional
 - Nociones de la Distribución Normal Multivariada
- 2 Kriging Lineales
 - Kriging Simple
 - Kriging Ordinario
 - Kriging Universal

Introducción a la Predicción Espacial (Kriging)

Objetivo General: Predecir un proceso Z en un punto, denotado por s_0 donde el proceso no ha sido observado, a partir de un conjunto de n observaciones del proceso.

Introducción a la Predicción Espacial (Kriging)

Objetivo General: Predecir un proceso Z en un punto, denotado por s_0 donde el proceso no ha sido observado, a partir de un conjunto de n observaciones del proceso.

- Esta idea fue planteada originalmente por Krige (1951).

Introducción a la Predicción Espacial (Kriging)

Objetivo General: Predecir un proceso Z en un punto, denotado por s_0 donde el proceso no ha sido observado, a partir de un conjunto de n observaciones del proceso.

- Esta idea fue planteada originalmente por Krige (1951).
- Los trabajos empíricos de Krige para evaluar recursos mineros, fueron formalizados en la década del 60 por el ingeniero francés Georges Matheron.

Introducción a la Predicción Espacial (Kriging)

Objetivo General: Predecir un proceso Z en un punto, denotado por s_0 donde el proceso no ha sido observado, a partir de un conjunto de n observaciones del proceso.

- Esta idea fue planteada originalmente por Krige (1951).
- Los trabajos empíricos de Krige para evaluar recursos mineros, fueron formalizados en la década del 60 por el ingeniero francés Georges Matheron.
- Georges Matheron desarrolló la técnica denominada **kriging** en honor a la investigación de Krige en el campo de la geoestadística.

Introducción a la Predicción Espacial (Kriging)

Notacion:

- $\mathbf{Z} = (Z(\mathbf{s}_1), Z(\mathbf{s}_2), \dots, Z(\mathbf{s}_n))^T$ datos observados.
- $Z(\mathbf{s}_0)$ desconocido pero fijo.
- $P(\mathbf{Z}, g(Z(\mathbf{s}_0)))$: Predictor de $g(Z(\mathbf{s}_0))$ en el punto \mathbf{s}_0 .
- Caso de interés es $g(Z(\mathbf{s}_0)) = Z(\mathbf{s}_0)$
- $P(\mathbf{Z}, Z(\mathbf{s}_0)) = P(\mathbf{Z}, \mathbf{s}_0)$.
- $L = L(\mathbf{s}_0, \mathbf{Z}) = (Z(\mathbf{s}_0) - P(\mathbf{Z}, \mathbf{s}_0))^2$: Pérdida Cuadrática.
- $E[L] = \mathbb{E} \left[(Z(\mathbf{s}_0) - P(\mathbf{Z}, \mathbf{s}_0))^2 \right]$: función de Riesgo.

Introducción a la Predicción Espacial (Kriging)

Objetivo Específico: Obtener $P^0(Z, \mathbf{s}_0)$ como aquel que minimiza la función de riesgo, es decir,

$$P^0(Z, \mathbf{s}_0) = \operatorname{argmin} \left\{ \mathbb{E} \left[(Z(\mathbf{s}_0) - P(Z, \mathbf{s}_0))^2 \right] \right\}$$

Introducción a la Predicción Espacial

Las herramientas que se utilizan para resolver el problema de minimización anterior son:

Las herramientas que se utilizan para resolver el problema de minimización anterior son:

- 1 Esperanzas Condicionales

Las herramientas que se utilizan para resolver el problema de minimización anterior son:

- 1 Esperanzas Condicionales
- 2 Distribución Normal Multivariada

Introducción a la Predicción Espacial

Las herramientas que se utilizan para resolver el problema de minimización anterior son:

- 1 Esperanzas Condicionales
- 2 Distribución Normal Multivariada
- 3 Regresión Lineal Multiple

Introducción a la Predicción Espacial

Las herramientas que se utilizan para resolver el problema de minimización anterior son:

- 1 Esperanzas Condicionales
- 2 Distribución Normal Multivariada
- 3 Regresión Lineal Múltiple
- 4 Multiplicadores de Lagrange

Definición: Sean X e Y dos variables aleatorias con función de densidad conjunta $f_{X,Y}(x, y)$ y densidades marginales $f_X(x)$ y $f_Y(y)$. Entonces la densidad condicional de $Y|X = x$ es

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

Además su valor esperado es

$$\mathbb{E}[Y|X = x] = \int y f_{Y|X=x}(y) dy$$

Propiedades:

- 1 $Y|X$ es una variable aleatoria.

Propiedades:

- ① $Y|X$ es una variable aleatoria.
- ② $\mathbb{E}[Y|X = x]$ es un número.

Propiedades:

- 1 $Y|X$ es una variable aleatoria.
- 2 $\mathbb{E}[Y|X = x]$ es un número.
- 3 $\mathbb{E}[Y|X]$ es una variable aleatoria, función de X

Propiedades:

- 1 $Y|X$ es una variable aleatoria.
- 2 $\mathbb{E}[Y|X = x]$ es un número.
- 3 $\mathbb{E}[Y|X]$ es una variable aleatoria, función de X
- 4 $\mathbb{E}[\mathbb{E}[Y|X]] = \mathbb{E}[Y]$

Resultado: Sea r una función tal que $r(X)$ está bien definida. Entonces se tienen los siguientes resultados:

Resultado: Sea r una función tal que $r(X)$ está bien definida. Entonces se tienen los siguientes resultados:

① $\mathbb{E}[r(X)Y|X] = r(X)\mathbb{E}[Y|X]$

Resultado: Sea r una función tal que $r(X)$ está bien definida. Entonces se tienen los siguientes resultados:

❶ $\mathbb{E}[r(X)Y|X] = r(X)\mathbb{E}[Y|X]$

❷ $\mathbb{E}[r(X)\mathbb{E}[Y|X]] = \mathbb{E}[r(X)Y]$

Resultado: Sea r una función tal que $r(X)$ está bien definida. Entonces se tienen los siguientes resultados:

- ❶ $\mathbb{E}[r(X)Y|X] = r(X)\mathbb{E}[Y|X]$
- ❷ $\mathbb{E}[r(X)\mathbb{E}[Y|X]] = \mathbb{E}[r(X)Y]$
- ❸ $Y - \mathbb{E}[Y|X]$ y $r(X)$ son no correlacionados.

Resultado: Sea r una función tal que $r(X)$ está bien definida. Entonces se tienen los siguientes resultados:

- ❶ $\mathbb{E}[r(X)Y|X] = r(X)\mathbb{E}[Y|X]$
- ❷ $\mathbb{E}[r(X)\mathbb{E}[Y|X]] = \mathbb{E}[r(X)Y]$
- ❸ $Y - \mathbb{E}[Y|X]$ y $r(X)$ son no correlacionados.

Demostración:(1) por definición. (2) directo desde la Propiedad (4). Para (3) calcular la covarianza entre $Y - \mathbb{E}[Y|X]$ y $r(X)$, luego concluir.

Teorema: (Mejor Predictor) Sea Y una variable aleatoria, sea \mathbf{U} un vector aleatorio y sea g una función. Entonces una de las siguientes condiciones se cumple:

$$(a) \quad \mathbb{E} \left[(Y - g(\mathbf{U}))^2 \right] = \infty$$

$$(b) \quad \mathbb{E} \left[(Y - \mathbb{E}[Y|\mathbf{U}])^2 \right] \leq \mathbb{E} \left[(Y - g(\mathbf{U}))^2 \right]$$

Teorema: (Mejor Predictor) Sea Y una variable aleatoria, sea \mathbf{U} un vector aleatorio y sea g una función. Entonces una de las siguientes condiciones se cumple:

$$(a) \quad \mathbb{E} \left[(Y - g(\mathbf{U}))^2 \right] = \infty$$

$$(b) \quad \mathbb{E} \left[(Y - \mathbb{E}[Y|\mathbf{U}])^2 \right] \leq \mathbb{E} \left[(Y - g(\mathbf{U}))^2 \right]$$

Demostración: Sumar y restar $\mathbb{E}[Y|\mathbf{U}]$ en $\mathbb{E} \left[(Y - g(\mathbf{U}))^2 \right]$ y luego concluir usando el resultado anterior.

Consecuencia: $\mathbb{E}[Y|U]$ minimiza la función de pérdida cuadrática.

Consecuencia: $\mathbb{E}[Y|U]$ minimiza la función de pérdida cuadrática.

Por lo tanto, se tiene que

$$P^0(Z, s_0) = \mathbb{E}[Z(s_0)|Z]$$

Consecuencia: $\mathbb{E}[Y|U]$ minimiza la función de pérdida cuadrática.

Por lo tanto, se tiene que

$$P^0(Z, \mathbf{s}_0) = \mathbb{E}[Z(\mathbf{s}_0)|Z]$$

Más aún,

$$\mathbb{E} \left[(Z(\mathbf{s}_0) - P^0(Z, \mathbf{s}_0))^2 \right] = \mathbb{V}[Z(\mathbf{s}_0)] - \mathbb{V} [P^0(Z, \mathbf{s}_0)]$$

En el caso Gaussiano, la esperanza condicional tiene forma explícita.

Distribución Normal Multivariada

En el caso Gaussiano, la esperanza condicional tiene forma explicita.

Suponga que $\mathbf{W} = (\mathbf{V}, \mathbf{U})^\top \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ tal que

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_V \\ \boldsymbol{\mu}_U \end{pmatrix}; \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_V & \boldsymbol{\Sigma}_{VU} \\ \boldsymbol{\Sigma}_{UV} & \boldsymbol{\Sigma}_U \end{bmatrix}$$

Entonces, $\mathbf{V}|\mathbf{U} \sim \mathcal{N}(\mathbb{E}[\mathbf{V}|\mathbf{U}], \mathbb{V}[\mathbf{V}|\mathbf{U}])$, donde

$$\begin{aligned} \mathbb{E}[\mathbf{V}|\mathbf{U}] &= \boldsymbol{\mu}_V + \boldsymbol{\Sigma}_{VU}\boldsymbol{\Sigma}_U^{-1}(\mathbf{U} - \boldsymbol{\mu}_U) \\ \mathbb{V}[\mathbf{V}|\mathbf{U}] &= \boldsymbol{\Sigma}_V - \boldsymbol{\Sigma}_{VU}\boldsymbol{\Sigma}_U^{-1}\boldsymbol{\Sigma}_{UV} \end{aligned}$$

Distribución Normal Multivariada

En términos de la notación anterior,

$$V = Z(\mathbf{s}_0); \quad \mathbf{U} = \mathbf{Z}$$

$$\mathbb{E}[Z(\mathbf{s}_0)] = \mu(\mathbf{s}_0); \quad \mathbb{E}[\mathbf{Z}] = \boldsymbol{\mu}(\mathbf{s})$$

$$\mathbb{V}[\mathbf{Z}] = \boldsymbol{\Sigma}; \quad \text{cov}(\mathbf{Z}, Z(\mathbf{s}_0)) = \mathbf{C}$$

Distribución Normal Multivariada

En términos de la notación anterior,

$$V = Z(\mathbf{s}_0); \quad \mathbf{U} = \mathbf{Z}$$

$$\mathbb{E}[Z(\mathbf{s}_0)] = \mu(\mathbf{s}_0); \quad \mathbb{E}[\mathbf{Z}] = \boldsymbol{\mu}(\mathbf{s})$$

$$\mathbb{V}[\mathbf{Z}] = \boldsymbol{\Sigma}; \quad \text{cov}(\mathbf{Z}, Z(\mathbf{s}_0)) = \mathbf{C}$$

Entonces

$$P^0(Z, \mathbf{s}_0) = \mu(\mathbf{s}_0) + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \boldsymbol{\mu}(\mathbf{s}))$$

Distribución Normal Multivariada

En términos de la notación anterior,

$$V = Z(\mathbf{s}_0); \quad \mathbf{U} = \mathbf{Z}$$

$$\mathbb{E}[Z(\mathbf{s}_0)] = \mu(\mathbf{s}_0); \quad \mathbb{E}[\mathbf{Z}] = \boldsymbol{\mu}(\mathbf{s})$$

$$\mathbb{V}[\mathbf{Z}] = \boldsymbol{\Sigma}; \quad \text{cov}(\mathbf{Z}, Z(\mathbf{s}_0)) = \mathbf{C}$$

Entonces

$$P^0(Z, \mathbf{s}_0) = \mu(\mathbf{s}_0) + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \boldsymbol{\mu}(\mathbf{s}))$$

$$\Rightarrow P^0(Z, \mathbf{s}_0) = \lambda_0 + \sum_{i=1}^n \lambda_i Z(\mathbf{s}_i)$$

Distribución Normal Multivariada

En términos de la notación anterior,

$$V = Z(\mathbf{s}_0); \quad \mathbf{U} = \mathbf{Z}$$

$$\mathbb{E}[Z(\mathbf{s}_0)] = \mu(\mathbf{s}_0); \quad \mathbb{E}[\mathbf{Z}] = \boldsymbol{\mu}(\mathbf{s})$$

$$\mathbb{V}[\mathbf{Z}] = \boldsymbol{\Sigma}; \quad \text{cov}(\mathbf{Z}, Z(\mathbf{s}_0)) = \mathbf{C}$$

Entonces

$$P^0(Z, \mathbf{s}_0) = \mu(\mathbf{s}_0) + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \boldsymbol{\mu}(\mathbf{s}))$$

$$\Rightarrow P^0(Z, \mathbf{s}_0) = \lambda_0 + \sum_{i=1}^n \lambda_i Z(\mathbf{s}_i)$$

Además,

$$\mathbb{E} \left[\left(Z(\mathbf{s}_0) - P^0(Z, \mathbf{s}_0) \right)^2 \right] = \mathbb{V}[Z(\mathbf{s}_0)] - \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}$$

- 1 Introducción a la Predicción Espacial (Kriging)
 - Nociones de Esperanza Condicional
 - Nociones de la Distribución Normal Multivariada

- 2 Kriging Lineales
 - Kriging Simple
 - Kriging Ordinario
 - Kriging Universal

Kriging Simple

Sea $\mathbf{Z}(\mathbf{s}) = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top}$ tal que

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Kriging Simple

Sea $\mathbf{Z}(\mathbf{s}) = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top}$ tal que

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Simple:

- $\boldsymbol{\mu}(\mathbf{s})$ es conocido
- $\boldsymbol{\Sigma}$ es conocido

Kriging Simple

Sea $\mathbf{Z}(\mathbf{s}) = (Z(\mathbf{s}_1), \dots, Z(\mathbf{s}_n))^{\top}$ tal que

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Simple:

- $\boldsymbol{\mu}(\mathbf{s})$ es conocido
- $\boldsymbol{\Sigma}$ es conocido

Asumir que

$$P(Z, \mathbf{s}_0) = \lambda_0 + \boldsymbol{\lambda}^{\top} \mathbf{Z}, \quad \boldsymbol{\lambda}^{\top} = (\lambda_1, \dots, \lambda_n), \quad \lambda_i \in \mathbb{R}.$$

Notar que λ_0 y $\boldsymbol{\lambda}$ son parámetros desconocidos que se obtienen minimizando

$$\mathbb{E} \left[(Z(\mathbf{s}_0) - P(Z, \mathbf{s}_0))^2 \right]$$

Kriging Simple

La condición de insesgamiento:

$$\mathbb{E}[P(Z, \mathbf{s}_0)] = \mathbb{E}[Z(\mathbf{s}_0)] \iff \lambda_0 + \boldsymbol{\lambda}^\top \boldsymbol{\mu}(\mathbf{s}) = \mu(\mathbf{s}_0)$$

Se satisface si $\lambda_0 = \mu(\mathbf{s}_0) - \boldsymbol{\lambda}^\top \boldsymbol{\mu}(\mathbf{s})$.

Kriging Simple

La condición de insesgamiento:

$$\mathbb{E}[P(Z, \mathbf{s}_0)] = \mathbb{E}[Z(\mathbf{s}_0)] \iff \lambda_0 + \boldsymbol{\lambda}^\top \boldsymbol{\mu}(\mathbf{s}) = \mu(\mathbf{s}_0)$$

Se satisface si $\lambda_0 = \mu(\mathbf{s}_0) - \boldsymbol{\lambda}^\top \boldsymbol{\mu}(\mathbf{s})$.

Luego,

$$\mathbb{E} \left[(P(Z, \mathbf{s}_0) - Z(\mathbf{s}_0))^2 \right] = \mathbb{V} \left[\boldsymbol{\lambda}^\top \mathbf{Z} - Z(\mathbf{s}_0) \right] = \underbrace{\boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda} + \sigma^2 - 2\boldsymbol{\lambda}^\top \mathbf{C}}_{g(\boldsymbol{\lambda})}$$

donde $\sigma^2 = \mathbb{V}[Z(\mathbf{s}_0)]$, $\boldsymbol{\Sigma} = \mathbb{V}[\mathbf{Z}]$ y $\mathbf{C} = \text{cov}(Z(\mathbf{s}_0), \mathbf{Z})$.

$$\nabla g(\boldsymbol{\lambda}) = \mathbf{0} \quad \Leftrightarrow \quad 2\boldsymbol{\Sigma}\boldsymbol{\lambda} - 2\boldsymbol{C} = 0 \quad \Rightarrow \quad \boldsymbol{\lambda} = \boldsymbol{\Sigma}^{-1}\boldsymbol{C}$$

$$\nabla g(\boldsymbol{\lambda}) = \mathbf{0} \quad \Leftrightarrow \quad 2\boldsymbol{\Sigma}\boldsymbol{\lambda} - 2\mathbf{C} = 0 \quad \Rightarrow \quad \boldsymbol{\lambda} = \boldsymbol{\Sigma}^{-1}\mathbf{C}$$

Por lo tanto, el predictor por Kriging Simple de $Z(\mathbf{s}_0)$ es

$$P_{SK}(Z, \mathbf{s}_0) = \mu(\mathbf{s}_0) + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \boldsymbol{\mu}(\mathbf{s}))$$

Kriging Simple

$$\nabla g(\boldsymbol{\lambda}) = \mathbf{0} \quad \Leftrightarrow \quad 2\boldsymbol{\Sigma}\boldsymbol{\lambda} - 2\mathbf{C} = 0 \quad \Rightarrow \quad \boldsymbol{\lambda} = \boldsymbol{\Sigma}^{-1}\mathbf{C}$$

Por lo tanto, el predictor por Kriging Simple de $Z(\mathbf{s}_0)$ es

$$P_{SK}(Z, \mathbf{s}_0) = \mu(\mathbf{s}_0) + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \boldsymbol{\mu}(\mathbf{s}))$$

Además, la varianza de Predicción esta dada por

$$\sigma_{SK}^2(\mathbf{s}_0) = \sigma^2 - \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}$$

Comentario: En la práctica asumir que la media del proceso es conocida es un supuesto demasiado grande. Pero asumiendo que la media del proceso es $\mu(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$ ha sido bien especificada, se puede plantear el siguiente método:

Comentario: En la práctica asumir que la media del proceso es conocida es un supuesto demasiado grande. Pero asumiendo que la media del proceso es $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$ ha sido bien especificada, se puede plantear el siguiente método:

❶ Ajustar el modelo: $\hat{\boldsymbol{\beta}}_{LS} = (\mathbf{X}(\mathbf{s})^\top \mathbf{X}(\mathbf{s}))^{-1} \mathbf{X}(\mathbf{s})^\top \mathbf{Z}$

Comentario: En la práctica asumir que la media del proceso es conocida es un supuesto demasiado grande. Pero asumiendo que la media del proceso es $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$ ha sido bien especificada, se puede plantear el siguiente método:

- 1 Ajustar el modelo: $\hat{\boldsymbol{\beta}}_{LS} = (\mathbf{X}(\mathbf{s})^\top \mathbf{X}(\mathbf{s}))^{-1} \mathbf{X}(\mathbf{s})^\top \mathbf{Z}$
- 2 Determinar los Residuos: $\hat{\mathbf{e}} = \mathbf{Z} - \mathbf{X}(\mathbf{s})\hat{\boldsymbol{\beta}}$

Comentario: En la práctica asumir que la media del proceso es conocida es un supuesto demasiado grande. Pero asumiendo que la media del proceso es $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$ ha sido bien especificada, se puede plantear el siguiente método:

- 1 Ajustar el modelo: $\hat{\boldsymbol{\beta}}_{LS} = (\mathbf{X}(\mathbf{s})^\top \mathbf{X}(\mathbf{s}))^{-1} \mathbf{X}(\mathbf{s})^\top \mathbf{Z}$
- 2 Determinar los Residuos: $\hat{\mathbf{e}} = \mathbf{Z} - \mathbf{X}(\mathbf{s})\hat{\boldsymbol{\beta}}$
- 3 Realizar kriging simple sobre los residuos, obtener $P_{SK}(\hat{\mathbf{e}}, \mathbf{s}_0)$

Comentario: En la práctica asumir que la media del proceso es conocida es un supuesto demasiado grande. Pero asumiendo que la media del proceso es $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$ ha sido bien especificada, se puede plantear el siguiente método:

- 1 Ajustar el modelo: $\hat{\boldsymbol{\beta}}_{LS} = (\mathbf{X}(\mathbf{s})^\top \mathbf{X}(\mathbf{s}))^{-1} \mathbf{X}(\mathbf{s})^\top \mathbf{Z}$
- 2 Determinar los Residuos: $\hat{\mathbf{e}} = \mathbf{Z} - \mathbf{X}(\mathbf{s})\hat{\boldsymbol{\beta}}$
- 3 Realizar kriging simple sobre los residuos, obtener $P_{SK}(\hat{\mathbf{e}}, \mathbf{s}_0)$
- 4 Obtener el predictor de $Z(\mathbf{s}_0)$, $P(Z, \mathbf{s}_0) = \mathbf{X}(\mathbf{s})\hat{\boldsymbol{\beta}} + P_{SK}(\hat{\mathbf{e}}, \mathbf{s}_0)$

Criticas:

- $\hat{\beta}_{LS}$ no considera Σ

Criticas:

- $\hat{\beta}_{LS}$ no considera Σ
- Aún cuando, se utilice

$$\hat{\beta}_{GLS} = \left(\mathbf{X}(\mathbf{s})^\top \Sigma^{-1} \mathbf{X}(\mathbf{s}) \right)^{-1} \mathbf{X}(\mathbf{s})^\top \Sigma^{-1} \mathbf{Z}$$

Σ en general es desconocido.

Criticas:

- $\hat{\beta}_{LS}$ no considera Σ
- Aún cuando, se utilice

$$\hat{\beta}_{GLS} = \left(\mathbf{X}(s)^\top \Sigma^{-1} \mathbf{X}(s) \right)^{-1} \mathbf{X}(s)^\top \Sigma^{-1} \mathbf{Z}$$

Σ en general es desconocido.

- Obtener $\hat{\Sigma}_{\text{variograma}} \longrightarrow \hat{\beta}$ sesgado.

Kriging Ordinario

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde} \quad \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Kriging Ordinario

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Ordinario:

- $\boldsymbol{\mu}(\mathbf{s}) = \boldsymbol{\mu}$, $\forall \mathbf{s}$, con $\boldsymbol{\mu} \in \mathbb{R}$ desconocido
- $\boldsymbol{\Sigma}$ es conocido

Kriging Ordinario

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Ordinario:

- $\mu(\mathbf{s}) = \mu, \quad \forall \mathbf{s}$, con $\mu \in \mathbb{R}$ desconocido
- $\boldsymbol{\Sigma}$ es conocido

Es decir,

$$\mathbf{Z}(\mathbf{s}) = \mu \mathbf{1} + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Kriging Ordinario

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Ordinario:

- $\mu(\mathbf{s}) = \mu, \quad \forall \mathbf{s}$, con $\mu \in \mathbb{R}$ desconocido
- $\boldsymbol{\Sigma}$ es conocido

Es decir,

$$\mathbf{Z}(\mathbf{s}) = \mu \mathbf{1} + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Nuevamente asumir que

$$P(Z, \mathbf{s}_0) = \lambda_0 + \boldsymbol{\lambda}^\top \mathbf{Z}, \quad \boldsymbol{\lambda}^\top = (\lambda_1, \dots, \lambda_n), \quad \lambda_i \in \mathbb{R}.$$

La condición de insesgamiento:

$$\mathbb{E}[P(Z, \mathbf{s}_0)] = \mathbb{E}[Z(\mathbf{s}_0)] \iff \lambda_0 + \boldsymbol{\lambda}^\top \mu \mathbf{1} = \mu$$

pero ahora $\lambda_0 = \mu(\mathbf{s}_0) - \boldsymbol{\lambda}^\top \mu \mathbf{1}$ no es posible ya que μ es desconocido .

La condición de insesgamiento:

$$\mathbb{E}[P(Z, \mathbf{s}_0)] = \mathbb{E}[Z(\mathbf{s}_0)] \iff \lambda_0 + \boldsymbol{\lambda}^\top \mu \mathbf{1} = \mu$$

pero ahora $\lambda_0 = \mu(\mathbf{s}_0) - \boldsymbol{\lambda}^\top \mu \mathbf{1}$ no es posible ya que μ es desconocido .

Al observar la condición de insesgamiento como un polinomio en μ , obtenemos

$$\lambda_0 = 0, \quad \wedge \quad \boldsymbol{\lambda}^\top \mathbf{1} - 1 = 0 \implies \sum_{i=1}^n \lambda_i = 1$$

El problema es

$$\min_{\boldsymbol{\lambda}} \mathbb{E} \left[\left(\boldsymbol{\lambda}^\top \mathbf{Z} - Z(\mathbf{s}_0) \right)^2 \right] \quad \text{s.a.} \quad \boldsymbol{\lambda}^\top \mathbf{1} - 1 = 0$$

Utilizando multiplicadores de Lagrange, la función objetivo es

$$Q(\boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda} + \sigma^2 - 2\boldsymbol{\lambda}^\top \mathbf{C} - 2m \left(\boldsymbol{\lambda}^\top \mathbf{1} - 1 \right)$$

donde m es el multiplicador de Lagrange.

Al resolver $\nabla Q = \mathbf{0}$ se obtiene que

$$m = \frac{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1}} \quad \wedge \quad \boldsymbol{\lambda}^\top = \left(\mathbf{C} + \mathbf{1} \frac{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1}} \right) \boldsymbol{\Sigma}^{-1}$$

Obteniendo,

$$P_{OK}(Z, \mathbf{s}_0) = \hat{\mu} + \mathbf{C}^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Z} - \hat{\mu} \mathbf{1})$$

donde $\hat{\mu} = (\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1})^{-1} \mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{Z}$.

Al resolver $\nabla Q = \mathbf{0}$ se obtiene que

$$m = \frac{\mathbf{1} - \mathbf{1}^\top \Sigma^{-1} \mathbf{C}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \quad \wedge \quad \boldsymbol{\lambda}^\top = \left(\mathbf{C} + \mathbf{1} \frac{\mathbf{1} - \mathbf{1}^\top \Sigma^{-1} \mathbf{C}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \right) \Sigma^{-1}$$

Obteniendo,

$$P_{OK}(Z, \mathbf{s}_0) = \hat{\mu} + \mathbf{C}^\top \Sigma^{-1} (\mathbf{Z} - \hat{\mu} \mathbf{1})$$

donde $\hat{\mu} = (\mathbf{1}^\top \Sigma^{-1} \mathbf{1})^{-1} \mathbf{1}^\top \Sigma^{-1} \mathbf{Z}$.

Además,

$$\sigma_{OK}^2(\mathbf{s}_0) = \sigma^2 - \mathbf{C}^\top \Sigma^{-1} \mathbf{C} + \frac{(\mathbf{1} - \mathbf{1}^\top \Sigma^{-1} \mathbf{C})^2}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$$

Observaciones: Sea $C(\cdot)$ una función de covarianza isotrópica asociada al proceso Z .

Observaciones: Sea $C(\cdot)$ una función de covarianza isotrópica asociada al proceso Z .

- ❶ $\mathbb{V}[Z(\mathbf{s}_0)] = \sigma^2 = C(0)$.
- ❷ $\text{cov}(Z(\mathbf{s}_i), Z(\mathbf{s}_0)) = C(\|\mathbf{s}_i - \mathbf{s}_0\|)$.
- ❸ $\sigma_{SK}^2(\mathbf{s}_0) < \sigma_{OK}^2(\mathbf{s}_0)$.
- ❹ Estimar Σ a partir del variograma.
- ❺ Es posible escribir P_{OK} y σ_{OK}^2 en términos del variograma.

Modelamiento:

- 1 Ajustar un variograma a la muestra.
- 2 Obtener $\hat{\Sigma}$, $\hat{\mu}$, \hat{C} y $\hat{\sigma}^2$.
- 3 Calcular $P_{OK}(Z, \mathbf{s}_0)$ y $\sigma_{OK}^2(\mathbf{s}_0)$ para varios valores de \mathbf{s}_0

Modelamiento:

- 1 Ajustar un variograma a la muestra.
- 2 Obtener $\hat{\Sigma}$, $\hat{\mu}$, \hat{C} y $\hat{\sigma}^2$.
- 3 Calcular $P_{OK}(Z, \mathbf{s}_0)$ y $\sigma_{OK}^2(\mathbf{s}_0)$ para varios valores de \mathbf{s}_0

Critica: Asumir media constante es aún muy restrictivo.

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Kriging Universal

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Universal:

- $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$, $\forall \mathbf{s}$, con $\boldsymbol{\beta} \in \mathbb{R}^p$ desconocido.
- $\boldsymbol{\Sigma}$ es conocido

Kriging Universal

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Universal:

- $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$, $\forall \mathbf{s}$, con $\boldsymbol{\beta} \in \mathbb{R}^p$ desconocido.
- $\boldsymbol{\Sigma}$ es conocido

Es decir,

$$\mathbf{Z}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta} + \mathbf{e}(\mathbf{s}) \quad \text{y} \quad \mathbf{Z}(\mathbf{s}_0) = \mathbf{X}(\mathbf{s}_0)\boldsymbol{\beta} + \mathbf{e}(\mathbf{s}_0)$$

Kriging Universal

Considere el modelo

$$\mathbf{Z}(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \mathbf{e}(\mathbf{s}), \quad \text{donde } \mathbf{e}(\mathbf{s}) \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$$

Los supuestos sobre el Kriging Universal:

- $\boldsymbol{\mu}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta}$, $\forall \mathbf{s}$, con $\boldsymbol{\beta} \in \mathbb{R}^p$ desconocido.
- $\boldsymbol{\Sigma}$ es conocido

Es decir,

$$\mathbf{Z}(\mathbf{s}) = \mathbf{X}(\mathbf{s})\boldsymbol{\beta} + \mathbf{e}(\mathbf{s}) \quad \text{y} \quad \mathbf{Z}(\mathbf{s}_0) = \mathbf{X}(\mathbf{s}_0)\boldsymbol{\beta} + \mathbf{e}(\mathbf{s}_0)$$

Obs: $\mathbf{X}(\mathbf{s})$ tiene dimensión $n \times p$. $\mathbf{X}(\mathbf{s}_0)$ tiene dimensión $1 \times p$

Nuevamente asumir que

$$P(Z, \mathbf{s}_0) = \lambda_0 + \boldsymbol{\lambda}^\top \mathbf{Z}, \quad \boldsymbol{\lambda}^\top = (\lambda_1, \dots, \lambda_n), \quad \lambda_i \in \mathbb{R}.$$

Nuevamente asumir que

$$P(Z, \mathbf{s}_0) = \lambda_0 + \boldsymbol{\lambda}^\top \mathbf{Z}, \quad \boldsymbol{\lambda}^\top = (\lambda_1, \dots, \lambda_n), \quad \lambda_i \in \mathbb{R}.$$

La condición de insesgamiento:

$$\mathbb{E}[P(Z, \mathbf{s}_0)] = \mathbb{E}[Z(\mathbf{s}_0)] \iff \lambda_0 + \boldsymbol{\lambda}^\top \mathbf{X}(\mathbf{s})\boldsymbol{\beta} = \mathbf{X}(\mathbf{s}_0)\boldsymbol{\beta}$$

Al observar la condición de insesgamiento como un polinomio en $\boldsymbol{\beta}$, obtenemos

$$\lambda_0 = 0, \quad \wedge \quad \boldsymbol{\lambda}^\top \mathbf{X}(\mathbf{s}) - \mathbf{X}(\mathbf{s}_0) = \mathbf{0}$$

Es decir, el problema de minimización tiene p restricciones.

Considere la función objetivo

$$Q(\boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda} + \sigma^2 - 2\boldsymbol{\lambda}^\top \boldsymbol{C} - 2\boldsymbol{m}^\top \left(\boldsymbol{\lambda}^\top \boldsymbol{X}(\boldsymbol{s}) - \boldsymbol{X}(\boldsymbol{s}_0) \right)$$

Resolviendo la ecuación $\nabla Q = \mathbf{0}$, se obtiene que

$$P_{UK}(Z, \boldsymbol{s}_0) = \boldsymbol{X}(\boldsymbol{s}_0) \hat{\boldsymbol{\beta}} + \boldsymbol{C}^\top \boldsymbol{\Sigma}^{-1} \left(\boldsymbol{Z} - \boldsymbol{X}(\boldsymbol{s}) \hat{\boldsymbol{\beta}} \right)$$

donde $\hat{\boldsymbol{\beta}} = \left(\boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{X}(\boldsymbol{s}) \right)^{-1} \boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{Z}$.

Considere la función objetivo

$$Q(\boldsymbol{\lambda}) = \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda} + \sigma^2 - 2\boldsymbol{\lambda}^\top \boldsymbol{C} - 2\boldsymbol{m}^\top \left(\boldsymbol{\lambda}^\top \boldsymbol{X}(\boldsymbol{s}) - \boldsymbol{X}(\boldsymbol{s}_0) \right)$$

Resolviendo la ecuación $\nabla Q = \mathbf{0}$, se obtiene que

$$P_{UK}(Z, \boldsymbol{s}_0) = \boldsymbol{X}(\boldsymbol{s}_0) \hat{\boldsymbol{\beta}} + \boldsymbol{C}^\top \boldsymbol{\Sigma}^{-1} \left(\boldsymbol{Z} - \boldsymbol{X}(\boldsymbol{s}) \hat{\boldsymbol{\beta}} \right)$$

donde $\hat{\boldsymbol{\beta}} = \left(\boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{X}(\boldsymbol{s}) \right)^{-1} \boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{Z}$.

Además, si $\boldsymbol{A} = \left(\boldsymbol{X}(\boldsymbol{s}_0)^\top - \boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{C} \right)^\top$, entonces

$$\sigma_{UK}^2(\boldsymbol{s}_0) = \sigma^2 - \boldsymbol{C}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{C} + \boldsymbol{A}^\top \left(\boldsymbol{X}(\boldsymbol{s})^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{X}(\boldsymbol{s}) \right)^{-1} \boldsymbol{A}$$

Observaciones:

- Si $\mathbf{X}(\mathbf{s}) = \mathbf{1}$ se recuperan las ecuaciones del Kriging Ordinario.
- $\mathbf{X}(\mathbf{s})$ es la matriz de diseño y puede contener las direcciones o bien variables exógenas.
- Para estimar β y Σ al mismo tiempo usar el método de estimación REML.
- En la libreria **geoR** existen las funciones [krige.conv](#) y [ksline](#) para realizar las predicciones mediante kriging lineales.

- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.
- Rousseeuw, P. J., Croux, C., (1993). Alternatives of the median absolute deviation. *Journal of American Statistics Association*, **88**, 1273–1283.

¿Alguna Consulta?