

EPG3343 - Seminario de Estadística III

Clase 6

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



- 1 Kriging no Lineales
 - Kriging Lognormal
 - Trans-Gaussian Kriging
 - Kriging Indicador

- 2 Cambio de Soporte
 - Kriging por Bloques

1 Kriging no Lineales

- Kriging Lognormal
- Trans-Gaussian Kriging
- Kriging Indicador

2 Cambio de Soporte

- Kriging por Bloques

Kriging Lognormal

Suponga que $Z(\mathbf{s})$ es un campo aleatorio tal que

$$Y(\mathbf{s}) = \ln(Z(\mathbf{s})) \quad \text{es normal, } \forall \mathbf{s} \in D$$

Consecuentemente, $Z(\mathbf{s}) = \exp\{Y(\mathbf{s})\} > 0, \forall \mathbf{s} \in D$.

Kriging Lognormal

Suponga que $Z(\mathbf{s})$ es un campo aleatorio tal que

$$Y(\mathbf{s}) = \ln(Z(\mathbf{s})) \quad \text{es normal, } \forall \mathbf{s} \in D$$

Consecuentemente, $Z(\mathbf{s}) = \exp\{Y(\mathbf{s})\} > 0, \forall \mathbf{s} \in D$.

Asuma que $Y(\mathbf{s})$ tiene función de media $\mu_Y(\mathbf{s})$ y función de covarianza $C_Y(\mathbf{s}_1, \mathbf{s}_2)$, entonces (Aitchison & Brown, 1957)

$$\mu_Z(\mathbf{s}) = \exp\left\{\mu_Y(\mathbf{s}) + \frac{1}{2}C_Y(\mathbf{s}, \mathbf{s})\right\}$$

$$C_Z(\mathbf{s}_1, \mathbf{s}_2) = \mu_Z(\mathbf{s}_1)\mu_Z(\mathbf{s}_2) [\exp\{C_Y(\mathbf{s}_1, \mathbf{s}_2)\} - 1]$$

Obs: $\mu_Z(\mathbf{s}) \geq \exp\{\mu_Y(\mathbf{s})\}$.

Más aún, si $P^0(Y, \mathbf{s}_0)$ es el mejor predictor lineal de $Y(\mathbf{s}_0)$ entonces

$$\exp\{P^0(Y, \mathbf{s}_0)\}$$

es un predictor sesgado de $Z(\mathbf{s}_0)$.

Más aún, si $P^0(Y, \mathbf{s}_0)$ es el mejor predictor lineal de $Y(\mathbf{s}_0)$ entonces

$$\exp\{P^0(Y, \mathbf{s}_0)\}$$

es un predictor sesgado de $Z(\mathbf{s}_0)$.

Objetivo: Predecir insesgadamente $Z(\mathbf{s}_0)$ usando la información contenida en $\mathbf{Y} = (Y(\mathbf{s}_1), \dots, Y(\mathbf{s}_n))^{\top}$

Resultado: Según la notación anterior

$$\mathbb{E} [\exp\{P^0(Y, \mathbf{s}_0)\}] = \mu_Z \exp \left\{ -\frac{\sigma_Y^2}{2} + \frac{\mathbb{V}[P^0(Y, \mathbf{s}_0)]}{2} \right\}$$

donde $\mu_Z = \exp \left\{ \mathbb{E} [P^0(Y, \mathbf{s}_0)] - \frac{\mathbb{V}[P^0(Y, \mathbf{s}_0)]}{2} \right\}.$

Resultado: Según la notación anterior

$$\mathbb{E} [\exp\{P^0(Y, \mathbf{s}_0)\}] = \mu_Z \exp \left\{ -\frac{\sigma_Y^2}{2} + \frac{\mathbb{V}[P^0(Y, \mathbf{s}_0)]}{2} \right\}$$

donde $\mu_Z = \exp \left\{ \mathbb{E} [P^0(Y, \mathbf{s}_0)] - \frac{\mathbb{V}[P^0(Y, \mathbf{s}_0)]}{2} \right\}.$

Por lo tanto,

$$P_{LK}(Z, \mathbf{s}_0) = \exp \left\{ P^0(Y, \mathbf{s}_0) + \frac{\sigma_Y^2}{2} - \frac{\mathbb{V}[P^0(Y, \mathbf{s}_0)]}{2} \right\}$$

Kriging Lognormal

- **Kriging Simple:** Si $\mu(\mathbf{s})$ es conocido

$$P_{SLK}(Z, \mathbf{s}_0) = \exp \left\{ P_{SK}(Y, \mathbf{s}_0) - \frac{\sigma_{SK}^2(\mathbf{s}_0)}{2} \right\}$$

$$\sigma_{SLK}^2(\mathbf{s}_0) = P_{SLK}(Z, \mathbf{s}_0)^2 [\exp\{\sigma_{SK}^2(\mathbf{s}_0)\} - 1]$$

Kriging Lognormal

- **Kriging Simple:** Si $\mu(\mathbf{s})$ es conocido

$$P_{SLK}(Z, \mathbf{s}_0) = \exp \left\{ P_{SK}(Y, \mathbf{s}_0) - \frac{\sigma_{SK}^2(\mathbf{s}_0)}{2} \right\}$$

$$\sigma_{SLK}^2(\mathbf{s}_0) = P_{SLK}(Z, \mathbf{s}_0)^2 [\exp\{\sigma_{SK}^2(\mathbf{s}_0)\} - 1]$$

- **Kriging Ordinario:** Si $\mu(\mathbf{s}) = \mu$, μ constante desconocida

$$P_{OLK}(Z, \mathbf{s}_0) = \exp \left\{ P_{OK}(Y, \mathbf{s}_0) - \frac{\sigma_{SK}^2(\mathbf{s}_0)}{2} - m_y \right\}$$

$$\sigma_{OLK}^2(\mathbf{s}_0) = \exp\{2\mu_Y + \sigma_Y^2\} \exp\{\sigma_Y^2\} * \\ [1 + (\exp\{-\sigma_{OK}^2(\mathbf{s}_0) + m_y\} \exp\{m_y - 2\})]$$

donde m_y es el multiplicador de Lagrange obtenido usando Kriging ordinario para predecir $Y(\mathbf{s}_0)$.

Trans-Gaussian Kriging

El problema general de transformar un predictor a través de una función no lineal (de un campo Gaussiano) se denomina Trans-Gaussian Kriging.

Trans-Gaussian Kriging

El problema general de transformar un predictor a través de una función no lineal (de un campo Gaussiano) se denomina Trans-Gaussian Kriging.

Asuma que $Z(\mathbf{s}) = \varphi(Y(\mathbf{s}))$, donde

- $Y(\mathbf{s})$ es normal.
- $Y(\mathbf{s})$ es int. estacionario con media μ_y y semivariograma $\gamma_y(\mathbf{h})$.

Suponga que μ_y es desconocido y que se utiliza $P_{OK}(Y, \mathbf{s}_0)$ como el predictor de $Y(\mathbf{s}_0)$

Obs: En este contexto, el predictor natural de $Z(\mathbf{s}_0)$ es

$$P(Z, \mathbf{s}_0) = \varphi(P_{OK}(Y, \mathbf{s}_0))$$

el cual podría ser sesgado, tal como el caso del lognormal kriging.

Obs: En este contexto, el predictor natural de $Z(\mathbf{s}_0)$ es

$$P(Z, \mathbf{s}_0) = \varphi(P_{OK}(Y, \mathbf{s}_0))$$

el cual podría ser sesgado, tal como el caso del lognormal kriging.

Para resolver el problema del sesgo, considere las expansiones en serie de Taylor de la función $\varphi(\cdot)$ evaluada en

$$Y_0 = Y(\mathbf{s}_0) \quad \wedge \quad \hat{Y}_0 = P_{OK}(Y, \mathbf{s}_0)$$

entorno a μ_y .

Trans-Gaussian Kriging

$$\varphi(\hat{Y}_0) = \varphi(\mu_y) + \varphi'(\mu_y) (\hat{Y}_0 - \mu_y) + \frac{\varphi''(\mu_y)}{2} (\hat{Y}_0 - \mu_y)^2 \quad (1)$$

$$\varphi(Y_0) = \varphi(\mu_y) + \varphi'(\mu_y) (Y_0 - \mu_y) + \frac{\varphi''(\mu_y)}{2} (Y_0 - \mu_y)^2 \quad (2)$$

Aplicando esperanza en (1) y (2) se obtiene

$$\mathbb{E} [\varphi(\hat{Y}_0)] = \varphi(\mu_y) + \frac{\varphi''(\mu_y)}{2} \mathbb{E} \left[(\hat{Y}_0 - \mu_y)^2 \right]$$

$$\mathbb{E} [\varphi(Y_0)] = \varphi(\mu_y) + \frac{\varphi''(\mu_y)}{2} \mathbb{E} [(Y_0 - \mu_y)^2]$$

Condición Insesgado: $\mathbb{E} [\varphi(\hat{Y}_0)] = \mathbb{E} [\varphi(Y_0)]$. Obteniendo:

$$P_{tg}(Z, \mathbf{s}_0) = \varphi(P_{OK}(Y, \mathbf{s}_0)) + \frac{\varphi''(\mu_y)}{2} (\sigma_{OK}^2(\mathbf{s}_0) - m_y)$$

siendo m_y el multiplicador de lagrange del kriging ordinario.

Condición Insesgado: $\mathbb{E} [\varphi(\hat{Y}_0)] = \mathbb{E} [\varphi(Y_0)]$. Obteniendo:

$$P_{tg}(Z, \mathbf{s}_0) = \varphi(P_{OK}(Y, \mathbf{s}_0)) + \frac{\varphi''(\mu_y)}{2} (\sigma_{OK}^2(\mathbf{s}_0) - m_y)$$

siendo m_y el multiplicador de lagrange del kriging ordinario.

Más aún,

$$\mathbb{E} \left[(P_{tg}(Z, \mathbf{s}_0) - Z(\mathbf{s}_0))^2 \right] = [\varphi'(\mu_y)]^2 \sigma_{OK}^2(\mathbf{s}_0)$$

Obs: Existen algunas transformaciones que pueden ser usadas para obtener normalidad:

Obs: Existen algunas transformaciones que pueden ser usadas para obtener normalidad:

- Si $X \sim Poiss(\theta)$, entonces $\varphi(X) = \sqrt{X}$

Obs: Existen algunas transformaciones que pueden ser usadas para obtener normalidad:

- Si $X \sim Poiss(\theta)$, entonces $\varphi(X) = \sqrt{X}$
- Si $X \sim Bin(n, p)$, entonces $\varphi(X) = \arcsin(X)$

Obs: Existen algunas transformaciones que pueden ser usadas para obtener normalidad:

- Si $X \sim Poiss(\theta)$, entonces $\varphi(X) = \sqrt{X}$
- Si $X \sim Bin(n, p)$, entonces $\varphi(X) = \arcsin(X)$

Si lo que se busca es simetrizar X , entonces

$$\varphi_{\lambda}(X) = \begin{cases} \frac{X^{\lambda} - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \ln(X) & \text{si } \lambda = 0 \end{cases}$$

Trans-Gaussian Kriging

Deutsch & Journel (1992) propuso una forma empirica de obtener φ .

Trans-Gaussian Kriging

Deutsch & Journel (1992) propuso una forma empirica de obtener φ .

Sean

$\Phi(y)$ la función de distribución de una $\mathcal{N}(0, 1)$.

$F(z)$ la función de distribución empirica de los datos.

Y sean y_p y z_p los cuartiles de orden p de $\Phi(y)$ y $F(z)$ respectivamente, entonces

$$F(z_p) = \Phi(y_p)$$

Obteniendo

$y_p = \Phi^{-1}(F(z_p)) = \varphi^{-1}(z_p) :$ Normal Scores Transformation.

$z_p = F^{-1}(\Phi(y_p)) = \varphi(y_p) :$ Anamorphosis Transformation.

Kriging Indicador

Suponga que $\{Z(\mathbf{s}) : \mathbf{s} \in D \subset R^d\}$ es un proceso estrictamente estacionario y considere la transformación:

$$I(\mathbf{s}, a) = \mathbb{I}_A(\mathbf{s}) \quad \text{donde} \quad A = \{\mathbf{s} : Z(\mathbf{s}) \leq a\}$$

Kriging Indicador

Suponga que $\{Z(\mathbf{s}) : \mathbf{s} \in D \subset R^d\}$ es un proceso estrictamente estacionario y considere la transformación:

$$I(\mathbf{s}, a) = \mathbb{I}_A(\mathbf{s}) \quad \text{donde} \quad A = \{\mathbf{s} : Z(\mathbf{s}) \leq a\}$$

Obs: Bajo esta transformación no es aplicable trans-gaussian kriging, ya que $I(\mathbf{s}, a)$ transforma $Z(\mathbf{s})$ en un proceso binario donde el umbral a es conocido.

Kriging Indicador

Suponga que $\{Z(\mathbf{s}) : \mathbf{s} \in D \subset R^d\}$ es un proceso estrictamente estacionario y considere la transformación:

$$I(\mathbf{s}, a) = \mathbb{I}_A(\mathbf{s}) \quad \text{donde} \quad A = \{\mathbf{s} : Z(\mathbf{s}) \leq a\}$$

Obs: Bajo esta transformación no es aplicable trans-gaussian kriging, ya que $I(\mathbf{s}, a)$ transforma $Z(\mathbf{s})$ en un proceso binario donde el umbral a es conocido.

Como

$$\mathbb{E}[I(\mathbf{s}_0, a)] = \mathbb{P}[Z(\mathbf{s}_0) \leq a] = F(a)$$

es desconocido, es posible usar kriging ordinario para predecir $I(\mathbf{s}_0, a)$ a partir de los datos

$$\mathbf{I}(\mathbf{s}, a) = (I(\mathbf{s}_1, a), I(\mathbf{s}_2, a), \dots, I(\mathbf{s}_n, a))^{\top}$$

Luego,

$$P_{IK}[I(a), \mathbf{s}_0] = \boldsymbol{\lambda}^\top \mathbf{I}(\mathbf{s}, a)$$

donde el vector $\boldsymbol{\lambda}$ es obtenido de las ecuaciones de Kriging ordinario usando el variograma

$$2\gamma_I(\mathbf{h}) = \mathbb{V}[I(\mathbf{s} + \mathbf{h}, a) - I(\mathbf{s}, a)] = \mathbb{P}[Z(\mathbf{s} + \mathbf{h}) \leq a, Z(\mathbf{s}) \leq a]$$

Kriging Indicador

Luego,

$$P_{IK}[I(a), \mathbf{s}_0] = \boldsymbol{\lambda}^\top \mathbf{I}(\mathbf{s}, a)$$

donde el vector $\boldsymbol{\lambda}$ es obtenido de las ecuaciones de Kriging ordinario usando el variograma

$$2\gamma_I(\mathbf{h}) = \mathbb{V}[I(\mathbf{s} + \mathbf{h}, a) - I(\mathbf{s}, a)] = \mathbb{P}[Z(\mathbf{s} + \mathbf{h}) \leq a, Z(\mathbf{s}) \leq a]$$

Obs: Note que el Kriging Indicador provee información acerca de

$$\begin{aligned}\mathbb{E}[I(\mathbf{s}_0)|I(\mathbf{s}, a)] &= \mathbb{P}[Z(\mathbf{s}_0) \leq a | I(\mathbf{s}, a)] \\ &\neq \mathbb{P}[Z(\mathbf{s}_0) \leq a | \mathbf{Z}]\end{aligned}$$

Por lo tanto, hay pérdida de información al transformar $Z(\mathbf{s})$ en $I(\mathbf{s}, a)$.

Obs: En muchas aplicaciones, como análisis de riesgos, es de interes

$$\mathbb{P}[Z(\mathbf{s}_0) \geq a | \mathbf{Z}]$$

la cual puede ser estimada usando kriging indicador ya que

$$I^c(\mathbf{s}, a) = 1 - I(\mathbf{s}, a)$$

- 1 Kriging no Lineales
 - Kriging Lognormal
 - Trans-Gaussian Kriging
 - Kriging Indicador

- 2 Cambio de Soporte
 - Kriging por Bloques

Objetivo: Suponga que $B \subset D$ es una región en D y queremos predecir un solo valor (valor promedio) para dicha región. Es decir,

$$Z(B) = \frac{1}{|B|} \int_B Z(\mathbf{s}) d\mathbf{s}$$

Utilizando las ideas de kriging ordinario, se considera el predictor

$$P(Z, B) = \boldsymbol{\lambda}^\top \mathbf{Z}$$

Objetivo: Suponga que $B \subset D$ es una región en D y queremos predecir un solo valor (valor promedio) para dicha región. Es decir,

$$Z(B) = \frac{1}{|B|} \int_B Z(\mathbf{s}) d\mathbf{s}$$

Utilizando las ideas de kriging ordinario, se considera el predictor

$$P(Z, B) = \boldsymbol{\lambda}^\top \mathbf{Z}$$

Obs: Este problema es conocido como cambio de soporte.

Kriging por Bloques

Asumiendo que $\mathbb{E}[Z(\mathbf{s})] = \mathbb{E}[Z(B)] = \mu$ (**condición de Insesgado**)

Kriging por Bloques

Asumiendo que $\mathbb{E}[Z(\mathbf{s})] = \mathbb{E}[Z(B)] = \mu$ (**condición de Insesgado**)

Los pesos optimos se obtienen minimizando el ECMP, sugeto a $\mathbf{1}^\top \boldsymbol{\lambda} = 1$.

Kriging por Bloques

Asumiendo que $\mathbb{E}[Z(\mathbf{s})] = \mathbb{E}[Z(B)] = \mu$ (**condición de Insesgado**)

Los pesos optimos se obtienen minimizando el ECMP, sugeto a $\mathbf{1}^\top \boldsymbol{\lambda} = 1$.

Es decir, resolver el sistema:

$$\begin{cases} \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} - m = \mathbf{C}(B) \\ \mathbf{1}^\top \boldsymbol{\lambda} = 1 \end{cases}$$

Kriging por Bloques

Asumiendo que $\mathbb{E}[Z(\mathbf{s})] = \mathbb{E}[Z(B)] = \mu$ (**condición de Insesgado**)

Los pesos optimos se obtienen minimizando el ECMP, sugeto a $\mathbf{1}^\top \boldsymbol{\lambda} = 1$.

Es decir, resolver el sistema:

$$\begin{cases} \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} - m = \mathbf{C}(B) \\ \mathbf{1}^\top \boldsymbol{\lambda} = 1 \end{cases}$$

Cuya solución es:

$$\begin{cases} \boldsymbol{\lambda}^\top = \left(\mathbf{C}(B) + \mathbf{1} \frac{1 - \mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}(B)}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1}} \right)^\top \boldsymbol{\Sigma}^{-1} \\ m = \frac{1 - \mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{C}}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1}} \end{cases}$$

Obs: $C(B)$ representa la covarianza punto-bloque, la cual esta dada por

$$C(B) = \text{cov}(Z(B), Z(\mathbf{s})) = \frac{1}{|B|} \int_B C(\mathbf{u}, \mathbf{s}) d\mathbf{u} \quad (3)$$

Kriging por Bloques

Obs: $\mathbf{C}(B)$ representa la covarianza punto-bloque, la cual esta dada por

$$\mathbf{C}(B) = \text{cov}(Z(B), Z(\mathbf{s})) = \frac{1}{|B|} \int_B C(\mathbf{u}, \mathbf{s}) d\mathbf{u} \quad (3)$$

Adicionalmente, la varianza de predicción

$$\sigma^2(B) = \sigma^2(B, B) - \mathbf{C}^\top(B) \mathbf{\Sigma}^{-1} \mathbf{C}(B) + \frac{(1 - \mathbf{1}^\top \mathbf{\Sigma}^{-1} \mathbf{C}(B))^2}{\mathbf{1}^\top \mathbf{\Sigma}^{-1} \mathbf{1}}$$

donde

$$\sigma^2(B, B) = \text{cov}(Z(B), Z(B)) = \frac{1}{|B|^2} \int_B C(\mathbf{u}, \mathbf{v}) d\mathbf{u} d\mathbf{v} \quad (4)$$

Kriging por Bloques

En la práctica las integrales (3) y (4) se estiman discretizando B en los puntos $\{\mathbf{u}_j\}$, $j = 1, \dots, m$.

Kriging por Bloques

En la práctica las integrales (3) y (4) se estiman discretizando B en los puntos $\{\mathbf{u}_j\}$, $j = 1, \dots, m$.

$$\begin{cases} C(B) \approx \frac{1}{m} \sum_{j=1}^m C(\mathbf{u}_j, \mathbf{s}) \\ \sigma^2(B, B) \approx \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m C(\mathbf{u}_j, \mathbf{u}_i) \end{cases}$$

Kriging por Bloques

En la práctica las integrales (3) y (4) se estiman discretizando B en los puntos $\{\mathbf{u}_j\}$, $j = 1, \dots, m$.

$$\begin{cases} C(B) \approx \frac{1}{m} \sum_{j=1}^m C(\mathbf{u}_j, \mathbf{s}) \\ \sigma^2(B, B) \approx \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m C(\mathbf{u}_j, \mathbf{u}_i) \end{cases}$$

Obs: Las librerías (de R) que calculan este tipo de kriging son

- `sp`
- `gstat`
- `block`

- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.

¿Alguna Consulta?