

# EPG3343 - Seminario de Estadística III

## Clase 7

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



- 1 Modelos para Datos de Área
  - Modelo CAR
  - Modelo SAR

## 1 Modelos para Datos de Área

- Modelo CAR
- Modelo SAR

# Modelos para Datos de Área

- Con los datos regionales (área), una especificación directa de la matriz de varianza  $\Sigma$  limita la medida de proximidad espacial a las distancias entre las ubicaciones de los puntos que se supone representan cada región (por ejemplo, las distancias intercentroides).

# Modelos para Datos de Área

- Con los datos regionales (área), una especificación directa de la matriz de varianza  $\Sigma$  limita la medida de proximidad espacial a las distancias entre las ubicaciones de los puntos que se supone representan cada región (por ejemplo, las distancias intercentroides).
- En vez de utilizar un modelo geoestadístico para describir la dependencia espacial, es más apropiado, definir dicha dependencia a través de modelos de regresión espacial que pueden incorporar las estructuras de vecindad.

# Modelos para Datos de Área

- Con los datos regionales (área), una especificación directa de la matriz de varianza  $\Sigma$  limita la medida de proximidad espacial a las distancias entre las ubicaciones de los puntos que se supone representan cada región (por ejemplo, las distancias intercentroides).
- En vez de utilizar un modelo geoestadístico para describir la dependencia espacial, es más apropiado, definir dicha dependencia a través de modelos de regresión espacial que pueden incorporar las estructuras de vecindad.
- El análogo espacial (con respecto a series de tiempo) representa los datos en ubicaciones como una combinación lineal de valores vecinos.

# Modelos para Datos de Área

- Con los datos regionales (área), una especificación directa de la matriz de varianza  $\Sigma$  limita la medida de proximidad espacial a las distancias entre las ubicaciones de los puntos que se supone representan cada región (por ejemplo, las distancias intercentroides).
- En vez de utilizar un modelo geoestadístico para describir la dependencia espacial, es más apropiado, definir dicha dependencia a través de modelos de regresión espacial que pueden incorporar las estructuras de vecindad.
- El análogo espacial (con respecto a series de tiempo) representa los datos en ubicaciones como una combinación lineal de valores vecinos.
- Esta autorregresión induce la dependencia espacial de los datos.

- Ahora bien no existe una única forma de inducir la dependencia espacial a través de los vecinos, en esta sección veremos los métodos más comunes.



- Ahora bien no existe una única forma de inducir la dependencia espacial a través de los vecinos, en esta sección veremos los métodos más comunes.
- Una alternativa es un modelo tipo regresión donde

$$Y_j = f(Y_1, \dots, Y_{j-1}, Y_{j+1}, \dots, Y_n) + \epsilon_j, \quad j = 1, \dots, n$$

- Ahora bien no existe una única forma de inducir la dependencia espacial a través de los vecinos, en esta sección veremos los métodos más comunes.
- Una alternativa es un modelo tipo regresión donde

$$Y_j = f(Y_1, \dots, Y_{j-1}, Y_{j+1}, \dots, Y_n) + \epsilon_j, \quad j = 1, \dots, n$$

- Recordemos, que la matriz de contiguidad  $\mathbf{W}$  es 1 si los sitios están conectados y vale 0 si no lo están.

- Ahora bien no existe una única forma de inducir la dependencia espacial a través de los vecinos, en esta sección veremos los métodos más comunes.
- Una alternativa es un modelo tipo regresión donde

$$Y_j = f(Y_1, \dots, Y_{j-1}, Y_{j+1}, \dots, Y_n) + \epsilon_j, \quad j = 1, \dots, n$$

- Recordemos, que la matriz de contiguidad  $\mathbf{W}$  es 1 si los sitios están conectados y vale 0 si no lo están.
- Así el término  $\mathbf{WY}$  se denomina lag-espacial.

# Modelos para Datos de Área

- Por ejemplo, para  $n = 4$ , suponga que

$$\mathbf{W} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{pmatrix} \Rightarrow \mathbf{WY} = \begin{pmatrix} Y_2 \\ Y_1 + Y_3 + Y_4 \\ Y_2 + Y_4 \\ Y_2 + Y_3 \end{pmatrix}$$

Un posible modelo corresponde a

$$\mathbf{Y} = \rho \mathbf{WY} + \boldsymbol{\epsilon}$$

donde  $\rho$  es un parámetro adecuado.

# Modelos para Datos de Área

- Por ejemplo, para  $n = 4$ , suponga que

$$\mathbf{W} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{pmatrix} \Rightarrow \mathbf{WY} = \begin{pmatrix} Y_2 \\ Y_1 + Y_3 + Y_4 \\ Y_2 + Y_4 \\ Y_2 + Y_3 \end{pmatrix}$$

Un posible modelo corresponde a

$$\mathbf{Y} = \rho \mathbf{WY} + \boldsymbol{\epsilon}$$

donde  $\rho$  es un parámetro adecuado.

- Notar que  $Y_1$  es solo explicado por  $Y_2$ , mientras que  $Y_2$  es explicado por  $Y_1, Y_3$ , e  $Y_4$ . Para evitar esto se propone estandarizar la matriz  $\mathbf{W}$ .

# Modelos para Datos de Área

- **Estandarización por fila:** Consiste en dividir cada elemento por la suma de la fila a la que pertenece, es decir,

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum_{j=1}^n w_{ij}}$$

# Modelos para Datos de Área

- **Estandarización por fila:** Consiste en dividir cada elemento por la suma de la fila a la que pertenece, es decir,

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum_{j=1}^n w_{ij}}$$

- **Doble Estandarización:** Consiste en dividir cada elemento por la suma de todos los elementos, es decir,

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}}$$

# Modelos para Datos de Área

- **Estandarización por fila:** Consiste en dividir cada elemento por la suma de la fila a la que pertenece, es decir,

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum_{j=1}^n w_{ij}}$$

- **Doble Estandarización:** Consiste en dividir cada elemento por la suma de todos los elementos, es decir,

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}}$$

- **Estabilización de varianza:** Consiste en dos etapas

$$\text{1st: } w_{ij}^* = \frac{w_{ij}}{\sqrt{\sum_{j=1}^n w_{ij}^2}}; \quad \text{2nd: } \tilde{w}_{ij} = \frac{nw_{ij}^*}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}^*}$$

Surge en el contexto del Índice de Moran para datos Heterocedásticos.



# Modelos para Datos de Área

**Obs.:** En R tradicionalmente se denota por B, W, C, y S para la matriz de pesos Binaria, estandarizada por fila, global y estabilización de varianza, respectivamente.

# Modelos para Datos de Área

**Obs.:** En R tradicionalmente se denota por B, W, C, y S para la matriz de pesos Binaria, estandarizada por fila, global y estabilización de varianza, respectivamente.

Con esta nueva notación y la conexión de vecinos del ejemplo anterior

$$B = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{pmatrix}$$

- Estandarización por fila:

$$W = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1/3 & 0 & 1/3 & 1/3 \\ 0 & 1/2 & 0 & 1/2 \\ 0 & 1/2 & 1/2 & 0 \end{pmatrix} \Rightarrow WY = \begin{pmatrix} Y_2 \\ \frac{Y_1 + Y_3 + Y_4}{3} \\ \frac{Y_2 + Y_4}{2} \\ \frac{Y_2 + Y_3}{2} \end{pmatrix}$$

# Modelos para Datos de Área

- **Doble Estandarización:** Consiste en dividir cada elemento por la suma de todos los elementos, es decir,

$$C = \begin{pmatrix} 0 & 1/8 & 0 & 0 \\ 1/8 & 0 & 1/8 & 1/8 \\ 0 & 1/8 & 0 & 1/8 \\ 0 & 1/8 & 1/8 & 0 \end{pmatrix} \Rightarrow CY = \begin{pmatrix} \frac{Y_2}{8} \\ \frac{Y_1 + Y_3 + Y_4}{8} \\ \frac{Y_2 + Y_4}{8} \\ \frac{Y_2 + Y_3}{8} \end{pmatrix}$$

# Modelos para Datos de Área

- **Doble Estandarización:** Consiste en dividir cada elemento por la suma de todos los elementos, es decir,

$$C = \begin{pmatrix} 0 & 1/8 & 0 & 0 \\ 1/8 & 0 & 1/8 & 1/8 \\ 0 & 1/8 & 0 & 1/8 \\ 0 & 1/8 & 1/8 & 0 \end{pmatrix} \Rightarrow CY = \begin{pmatrix} \frac{Y_2}{8} \\ \frac{Y_1 + Y_3 + Y_4}{8} \\ \frac{Y_2 + Y_4}{8} \\ \frac{Y_2 + Y_3}{8} \end{pmatrix}$$

- **Estabilización de varianza:** Consiste en dos etapas

$$S = \frac{8}{\sqrt{3} + 2\sqrt{2}} \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1/\sqrt{3} & 0 & 1/\sqrt{3} & 1/\sqrt{3} \\ 0 & 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1/\sqrt{2} & 1/\sqrt{2} & 0 \end{pmatrix}$$

# Modelos para Datos de Área

- Para definir un modelo estadístico asociado a este tipo de dependencia se debe tener presente que no basta con conocer información (densidad) marginal de cada  $Y_i$ .

# Modelos para Datos de Área

- Para definir un modelo estadístico asociado a este tipo de dependencia se debe tener presente que no basta con conocer información (densidad) marginal de cada  $Y_i$ .
- Para recuperar la densidad conjunta es imprescindible contar con la información de las densidades marginales

# Modelos para Datos de Área

- Para definir un modelo estadístico asociado a este tipo de dependencia se debe tener presente que no basta con conocer información (densidad) marginal de cada  $Y_i$ .
- Para recuperar la densidad conjunta es imprescindible contar con la información de las densidades marginales
- La información de la condicionales debe ser consistente, por ejemplo, si  $n = 2$ , suponga que

$$Y_1 \mid Y_2 = y_2 \sim \mathcal{N}(\beta_0 + \beta_1 y_2, \sigma^2) \quad \wedge \quad Y_2 \mid Y_1 = y_1 \sim \mathcal{N}(\alpha_0 + \alpha_1 y_1^2, \sigma^2)$$

Entonces

$$\mathbb{E}[Y_1] = \mathbb{E}[\mathbb{E}[Y_1 \mid Y_2]] = \mathbb{E}[\beta_0 + \beta_1 Y_2] = \beta_0 + \beta_1 \mathbb{E}[Y_2]$$

$$\mathbb{E}[Y_2] = \mathbb{E}[\mathbb{E}[Y_2 \mid Y_1]] = \mathbb{E}[\alpha_0 + \alpha_1 Y_1^2] = \alpha_0 + \alpha_1 \mathbb{E}[Y_1^2]$$

La cual solo tienen solución trivial, significando que las medias son incompatibles.

## Lemma (de Brook)

*La densidad conjunta se puede obtener a partir de las densidades marginales mediante*

$$\begin{aligned} p(y_1, \dots, y_n) &= \frac{p(y_1 \mid y_2, \dots, y_n)}{p(y_{10} \mid y_2, \dots, y_n)} \cdot \frac{p(y_2 \mid y_{10}, y_3, \dots, y_n)}{p(y_{20} \mid y_{10}, y_3, \dots, y_n)} \cdot \\ &\quad \dots \cdot \frac{p(y_n \mid y_{10}, \dots, y_{n-1,0})}{p(y_{n0} \mid y_{10}, \dots, y_{n-1,0})} p(y_{10}, \dots, y_{n0}) \end{aligned}$$

*donde  $\mathbf{y}_0 = (y_{10}, \dots, y_{n0})$  es un punto fijo en el soporte de  $p(y_1, \dots, y_n)$*



## Definición (Conditional Autorregressive Models (Caso Gaussiano))

Suponga que

$$Y_i | y_j \stackrel{j \neq i}{\sim} \mathcal{N} \left( \sum_j b_{ij} y_j, \tau_i^2 \right), \quad i = 1, \dots, n.$$

Estas condicionales completas son compartibles, así por el lema de Brook se tiene

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2} \mathbf{y}^\top \mathbf{D}^{-1} (\mathbf{I} - \mathbf{B}) \mathbf{y} \right\},$$

donde  $\mathbf{B} = (b_{ij})$  y  $\mathbf{D} = \text{diag}(\tau_1^2, \dots, \tau_n^2)$

## Definición (Conditional Autorregressive Models (Caso Gaussiano))

Suponga que

$$Y_i | y_j \stackrel{j \neq i}{\sim} \mathcal{N} \left( \sum_j b_{ij} y_j, \tau_i^2 \right), \quad i = 1, \dots, n.$$

Estas condicionales completas son compartibles, así por el lema de Brook se tiene

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2} \mathbf{y}^\top \mathbf{D}^{-1} (\mathbf{I} - \mathbf{B}) \mathbf{y} \right\},$$

donde  $\mathbf{B} = (b_{ij})$  y  $\mathbf{D} = \text{diag}(\tau_1^2, \dots, \tau_n^2)$

**Pregunta:** ¿Tiene  $\mathbf{Y}$  una distribución normal multivariada?

# Modelo CAR

- Si  $\Sigma_y = (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D}$  fuese la varianza de  $\mathbf{Y}$  entonces  $\Sigma_y^\top = \Sigma_y$ , obteniendo las condiciones

$$\frac{b_{ij}}{\tau_i^2} = \frac{b_{ji}}{\tau_j^2} \quad \forall i, j \quad (1)$$

Claramente  $\mathbf{B}$  no necesita ser simétrica.

# Modelo CAR

- Si  $\Sigma_y = (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D}$  fuese la varianza de  $\mathbf{Y}$  entonces  $\Sigma_y^\top = \Sigma_y$ , obteniendo las condiciones

$$\frac{b_{ij}}{\tau_i^2} = \frac{b_{ji}}{\tau_j^2} \quad \forall i, j \quad (1)$$

Claramente  $\mathbf{B}$  no necesita ser simétrica.

- Volviendo a la matriz de proximidad  $\mathbf{W}$  (asumida simétrica), considere

$$b_{ij} = \frac{w_{ij}}{w_{i+}} \quad \wedge \quad \tau_i^2 = \frac{\tau^2}{w_{i+}}.$$

Sea  $D_w = \text{diag}(w_{1+}, \dots, w_{n+})$ , entonces

$$Y_i | y_j \stackrel{j \neq i}{\sim} \mathcal{N} \left( \frac{1}{w_{i+}} \sum_j w_{ij} y_j, \frac{\tau^2}{w_{i+}} \right),$$

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2} \mathbf{y}^\top (\mathbf{D}_w - \mathbf{W}) \mathbf{y} \right\}.$$

- Notar que la ultima expresión puede ser escrita como

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2\tau^2} \sum_{i \neq j} w_{ij} (y_i - y_j)^2 \right\}$$

- Notar que la ultima expresión puede ser escrita como

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2\tau^2} \sum_{i \neq j} w_{ij} (y_i - y_j)^2 \right\}$$

- Sin embargo, como  $(\mathbf{D}_w - \mathbf{W})\mathbf{1} = 0$  entonces  $\Sigma_y^{-1}$  es singular.

- Notar que la ultima expresión puede ser escrita como

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2\tau^2} \sum_{i \neq j} w_{ij} (y_i - y_j)^2 \right\}$$

- Sin embargo, como  $(\mathbf{D}_w - \mathbf{W})\mathbf{1} = 0$  entonces  $\Sigma_y^{-1}$  es singular.
- Esto significa que  $\Sigma$  no existe por lo que  $p(y_1, \dots, y_n)$  es impropia.

# Modelo CAR

- Notar que la ultima expresión puede ser escrita como

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2\tau^2} \sum_{i \neq j} w_{ij} (y_i - y_j)^2 \right\}$$

- Sin embargo, como  $(\mathbf{D}_w - \mathbf{W})\mathbf{1} = 0$  entonces  $\Sigma_y^{-1}$  es singular.
- Esto significa que  $\Sigma$  no existe por lo que  $p(y_1, \dots, y_n)$  es impropia.
- Este modelo en realidad es conocido como IAR (intrinsically autoregressive)



- Notar que la ultima expresión puede ser escrita como

$$p(y_1, \dots, y_n) \propto \exp \left\{ -\frac{1}{2\tau^2} \sum_{i \neq j} w_{ij} (y_i - y_j)^2 \right\}$$

- Sin embargo, como  $(\mathbf{D}_w - \mathbf{W})\mathbf{1} = 0$  entonces  $\Sigma_y^{-1}$  es singular.
- Esto significa que  $\Sigma$  no existe por lo que  $p(y_1, \dots, y_n)$  es impropia.
- Este modelo en realidad es conocido como IAR (intrinsically autoregressive)
- La impropiedad puede ser removida incluyendo un parámetro adicional,  $\rho$  y redefiniendo

$$\Sigma_y^{-1} = \mathbf{D}_w - \rho \mathbf{W}$$

# Modelo CAR

- Para garantizar que  $\Sigma_y^{-1}$  sea no singular se tiene que

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $\mathbf{D}_w^{-1/2} \mathbf{W} \mathbf{D}_w^{-1/2}$ .

- Para garantizar que  $\Sigma_y^{-1}$  sea no singular se tiene que

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $D_w^{-1/2} W D_w^{-1/2}$ .

- Reemplazando la matriz de adyacencia  $W$  por la matriz estandarizada por filas, denotada por,  $\widetilde{W}$ , entonces  $\Sigma_y^{-1}$  puede ser escrito como

$$\Sigma_y^{-1} = M^{-1}(I - \alpha \widetilde{W})$$

Así  $\Sigma_y^{-1}$  es invertible si  $|\alpha| < 1$  teniendo un comportamiento similar a una correlación.

# Modelo CAR

- Para garantizar que  $\Sigma_y^{-1}$  sea no singular se tiene que

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $D_w^{-1/2} W D_w^{-1/2}$ .

- Reemplazando la matriz de adyacencia  $W$  por la matriz estandarizada por filas, denotada por,  $\widetilde{W}$ , entonces  $\Sigma_y^{-1}$  puede ser escrito como

$$\Sigma_y^{-1} = M^{-1}(I - \alpha \widetilde{W})$$

Así  $\Sigma_y^{-1}$  es invertible si  $|\alpha| < 1$  teniendo un comportamiento similar a una correlación.

- Este último aspecto se aborda mejor en el modelo SAR.

# Modelo CAR

- Para garantizar que  $\Sigma_y^{-1}$  sea no singular se tiene que

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $D_w^{-1/2} W D_w^{-1/2}$ .

- Reemplazando la matriz de adyacencia  $W$  por la matriz estandarizada por filas, denotada por,  $\widetilde{W}$ , entonces  $\Sigma_y^{-1}$  puede ser escrito como

$$\Sigma_y^{-1} = M^{-1}(I - \alpha \widetilde{W})$$

Así  $\Sigma_y^{-1}$  es invertible si  $|\alpha| < 1$  teniendo un comportamiento similar a una correlación.

- Este último aspecto se aborda mejor en el modelo SAR.
- El modelo inicial puede ser escrito como

$$Y = BY + \epsilon \quad \equiv \quad (I - B)Y = \epsilon$$

- Si  $p(\mathbf{y})$  es propia, entonces  $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D})$  de donde

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}(\mathbf{I} - \mathbf{B})^{\top}).$$

- Si  $p(\mathbf{y})$  es propia, entonces  $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D})$  de donde

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}(\mathbf{I} - \mathbf{B})^{\top}).$$

- Es decir,  $\mathbf{Y}$  induce una distribución de los  $\boldsymbol{\epsilon}$ .

# Modelo CAR

- Si  $p(\mathbf{y})$  es propia, entonces  $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D})$  de donde

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}(\mathbf{I} - \mathbf{B})^{\top}).$$

- Es decir,  $\mathbf{Y}$  induce una distribución de los  $\boldsymbol{\epsilon}$ .
- Notar que los componentes de  $\boldsymbol{\epsilon}$  no son independientes y  $\text{cov}(\boldsymbol{\epsilon}, \mathbf{Y}) = \mathbf{D}$ .



# Modelo CAR

- Si  $p(\mathbf{y})$  es propia, entonces  $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D})$  de donde

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}(\mathbf{I} - \mathbf{B})^\top).$$

- Es decir,  $\mathbf{Y}$  induce una distribución de los  $\boldsymbol{\epsilon}$ .
- Notar que los componentes de  $\boldsymbol{\epsilon}$  no son independientes y  $\text{cov}(\boldsymbol{\epsilon}, \mathbf{Y}) = \mathbf{D}$ .
- El modelo SAR resuelve esta situación, asumiendo una distribución en el error y a partir de esta se induce una distribución a  $\mathbf{Y}$ .

# Modelo CAR

- Si  $p(\mathbf{y})$  es propia, entonces  $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \mathbf{D})$  de donde

$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}(\mathbf{I} - \mathbf{B})^{\top}).$$

- Es decir,  $\mathbf{Y}$  induce una distribución de los  $\boldsymbol{\epsilon}$ .
- Notar que los componentes de  $\boldsymbol{\epsilon}$  no son independientes y  $\text{cov}(\boldsymbol{\epsilon}, \mathbf{Y}) = \mathbf{D}$ .
- El modelo SAR resuelve esta situación, asumiendo una distribución en el error y a partir de esta se induce una distribución a  $\mathbf{Y}$ .
- Finalmente, es posible incluir un componente de regresión de la forma  $\mathbf{x}_i^{\top} \boldsymbol{\beta}$  de la forma:

$$\mathbf{Y} = \mathbf{B}\mathbf{Y} + \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

Sin embargo, veremos el modelo CAR solo como una distribución para el efecto aleatorio espacial.

## Definición (Simultaneous Autorregressive Models)

Suponga que

$$Y_i = \sum_j b_{ij} y_j + \epsilon_i, \quad i = 1, \dots, n, \quad \text{con} \quad \epsilon_i \sim \mathcal{N}(0, \sigma_i^2)$$

Si  $(\mathbf{I} - \mathbf{B})$  es de rango completo, entonces

$$\mathbf{Y} \sim \mathcal{N}\left(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \tilde{\mathbf{D}} (\mathbf{I} - \mathbf{B})^{-1}\right)^\top$$

donde  $\tilde{\mathbf{D}} = \text{diag}(\sigma_i^2)$ .

## Definición (Simultaneous Autorregressive Models)

Suponga que

$$Y_i = \sum_j b_{ij} y_j + \epsilon_i, \quad i = 1, \dots, n, \quad \text{con} \quad \epsilon_i \sim \mathcal{N}(0, \sigma_i^2)$$

Si  $(\mathbf{I} - \mathbf{B})$  es de rango completo, entonces

$$\mathbf{Y} \sim \mathcal{N}\left(\mathbf{0}, (\mathbf{I} - \mathbf{B})^{-1} \tilde{\mathbf{D}} ((\mathbf{I} - \mathbf{B})^{-1})^\top\right)$$

donde  $\tilde{\mathbf{D}} = \text{diag}(\sigma_i^2)$ .

**Obs.:**  $(\mathbf{I} - \mathbf{B})$  debe ser de rango completo pero no necesariamente simétrica.

- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.

# Modelo SAR

- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.
- La primera es  $\mathbf{B} = \rho \mathbf{W}$ , donde  $\mathbf{W}$  es la matriz de contigüidad.

- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.
- La primera es  $\mathbf{B} = \rho \mathbf{W}$ , donde  $\mathbf{W}$  es la matriz de contigüidad.
- En este caso

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $\mathbf{W}$ .

- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.
- La primera es  $\mathbf{B} = \rho \mathbf{W}$ , donde  $\mathbf{W}$  es la matriz de contigüidad.
- En este caso

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $\mathbf{W}$ .

- La segunda elección es  $\mathbf{B} = \alpha \widetilde{\mathbf{W}}$ , donde  $\widetilde{\mathbf{W}}$  es la matriz estocástica.



- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.
- La primera es  $\mathbf{B} = \rho \mathbf{W}$ , donde  $\mathbf{W}$  es la matriz de contigüidad.
- En este caso

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $\mathbf{W}$ .

- La segunda elección es  $\mathbf{B} = \alpha \widetilde{\mathbf{W}}$ , donde  $\widetilde{\mathbf{W}}$  es la matriz estocástica.
- En este caso  $\alpha \in (-1, 1)$  ya que todos los valores propios de  $\widetilde{\mathbf{W}}$  son menores a 1.

- Existen dos elecciones para  $\mathbf{B}$  se forma frecuente en la literatura.
- La primera es  $\mathbf{B} = \rho \mathbf{W}$ , donde  $\mathbf{W}$  es la matriz de contigüidad.
- En este caso

$$\rho \in \left( \frac{1}{\lambda_{(1)}}, \frac{1}{\lambda_{(n)}} \right)$$

donde  $\lambda_{(1)} < \dots < \lambda_{(n)}$  son los valores propios ordenados de  $\mathbf{W}$ .

- La segunda elección es  $\mathbf{B} = \alpha \widetilde{\mathbf{W}}$ , donde  $\widetilde{\mathbf{W}}$  es la matriz estocástica.
- En este caso  $\alpha \in (-1, 1)$  ya que todos los valores propios de  $\widetilde{\mathbf{W}}$  son menores a 1.
- Ambos  $\rho$  y  $\alpha$  se denominan parámetro de autocorrelación espacial.

- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.

¿Alguna Consulta?