

# EPG3343 - Seminario de Estadística III

## Clase 9

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



- 1 Análisis Bayesianos
  - Estimación Puntual
  - Métodos Numéricos para Estimadores Bayesianos
    - Metropolis-Hasting
  - Intervalos de credibilidad bayesianos

## 1 Análisis Bayesianos

- Estimación Puntual
- Métodos Numéricos para Estimadores Bayesianos
  - Metropolis-Hasting
- Intervalos de credibilidad bayesianos

# Estimación Puntual

## Estimación bayesiana

- La estimación bayesiana se diferencia de los métodos clásicos de estimación puntual, al tratar el parámetro  $\theta$  en un modelo de probabilidad como una variable aleatoria.

# Estimación Puntual

## Estimación bayesiana

- La estimación bayesiana se diferencia de los métodos clásicos de estimación puntual, al tratar el parámetro  $\theta$  en un modelo de probabilidad como una variable aleatoria.
- El valor de  $\theta$  en un modelo paramétrico  $f(x; \theta)$  tiene su propia fdp. denotada por  $\pi(\theta; \lambda)$ .

# Estimación Puntual

## Estimación bayesiana

- La estimación bayesiana se diferencia de los métodos clásicos de estimación puntual, al tratar el parámetro  $\theta$  en un modelo de probabilidad como una variable aleatoria.
- El valor de  $\theta$  en un modelo paramétrico  $f(x; \theta)$  tiene su propia fdp. denotada por  $\pi(\theta; \lambda)$ .
- $\pi(\theta; \lambda)$  se denomina distribución a priori y  $\lambda$  se conoce como hiperparámetro de la distribución a priori.

- La distribución a priori está basada en los posibles valores de  $\theta \in \Theta$  y refleja la incertidumbre sobre  $\theta$  antes de que se hayan recopilado los datos.

- La distribución a priori está basada en los posibles valores de  $\theta \in \Theta$  y refleja la incertidumbre sobre  $\theta$  antes de que se hayan recopilado los datos.
- La elección de la priori puede hacerse subjetiva u objetivamente y puede basarse en información previa sobre  $\theta$ , conveniencia matemática o la falta total de información previa sobre  $\theta$ .



# Estimación Puntual

- La distribución a priori está basada en los posibles valores de  $\theta \in \Theta$  y refleja la incertidumbre sobre  $\theta$  antes de que se hayan recopilado los datos.
- La elección de la priori puede hacerse subjetiva u objetivamente y puede basarse en información previa sobre  $\theta$ , conveniencia matemática o la falta total de información previa sobre  $\theta$ .
- Las prioris subjetivas contienen información importante sobre  $\theta$ , mientras que las prioris objetivas o prioris no informativas tienden a enfatizar la información contenida en la función de verosimilitud.

- La distribución a priori está basada en los posibles valores de  $\theta \in \Theta$  y refleja la incertidumbre sobre  $\theta$  antes de que se hayan recopilado los datos.
- La elección de la priori puede hacerse subjetiva u objetivamente y puede basarse en información previa sobre  $\theta$ , conveniencia matemática o la falta total de información previa sobre  $\theta$ .
- Las prioris subjetivas contienen información importante sobre  $\theta$ , mientras que las prioris objetivas o prioris no informativas tienden a enfatizar la información contenida en la función de verosimilitud.
- La información sobre  $\theta$  contenida en la distribución a priori y la información sobre  $\theta$  contenida en una muestra aleatoria del modelo de probabilidad  $f(x \mid \theta)$  se utilizan para estimar  $\theta$ .

- Cuando  $\theta$  es una variable aleatoria continua, el teorema de Bayes establece que la fdp de la distribución posterior es

$$f(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta; \lambda)}{f(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta; \lambda)}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)d\theta}.$$

- Cuando  $\theta$  es una variable aleatoria continua, el teorema de Bayes establece que la fdp de la distribución posterior es

$$f(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta; \lambda)}{f(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta; \lambda)}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)d\theta}.$$

- Cuando  $\theta$  es una variable aleatoria discreta, el teorema de Bayes establece que la fmp de la distribución posterior es

$$f(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta; \lambda)}{f(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta; \lambda)}{\sum_{\theta \in \Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)}.$$

- Cuando  $\theta$  es una variable aleatoria continua, el teorema de Bayes establece que la fdp de la distribución posterior es

$$f(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta; \lambda)}{f(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta; \lambda)}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)d\theta}.$$

- Cuando  $\theta$  es una variable aleatoria discreta, el teorema de Bayes establece que la fmp de la distribución posterior es

$$f(\theta|\mathbf{x}) = \frac{f(\mathbf{x}, \theta; \lambda)}{f(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta; \lambda)}{\sum_{\theta \in \Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)}.$$

- Note que en ambos casos,  $f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda)$ .

**Ejemplo:** Sea  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} b(1, \theta)$ . Suponga que  $\theta \sim U(0, 1)$  (priori no informativa). La función de verosimilitud para la muestra observada es

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^t (1 - \theta)^{n-t}, \quad \text{donde} \quad t = \sum_{i=1}^n x_i.$$

**Ejemplo:** Sea  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} b(1, \theta)$ . Suponga que  $\theta \sim U(0, 1)$  (priori no informativa). La función de verosimilitud para la muestra observada es

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^t (1 - \theta)^{n-t}, \quad \text{donde} \quad t = \sum_{i=1}^n x_i.$$

Ahora, dado que la distribución a priori es continua, la distribución posterior es

$$\begin{aligned} f(\theta|\mathbf{x}) &= \frac{L(\theta)\pi(\theta; \lambda)}{\int_{\Theta} L(\theta)\pi(\theta; \lambda)d\theta} = \frac{\theta^t(1 - \theta)^{n-t}}{\int_0^1 \theta^t(1 - \theta)^{n-t}d\theta} \\ &= \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t(1 - \theta)^{n-t}, \end{aligned}$$

**Ejemplo:** Sea  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} b(1, \theta)$ . Suponga que  $\theta \sim U(0, 1)$  (priori no informativa). La función de verosimilitud para la muestra observada es

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^t (1 - \theta)^{n-t}, \quad \text{donde} \quad t = \sum_{i=1}^n x_i.$$

Ahora, dado que la distribución a priori es continua, la distribución posterior es

$$\begin{aligned} f(\theta | \mathbf{x}) &= \frac{L(\theta)\pi(\theta; \lambda)}{\int_{\Theta} L(\theta)\pi(\theta; \lambda)d\theta} = \frac{\theta^t(1 - \theta)^{n-t}}{\int_0^1 \theta^t(1 - \theta)^{n-t}d\theta} \\ &= \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t(1 - \theta)^{n-t}, \end{aligned}$$

es decir,  $\theta | \mathbf{x} \sim \text{Beta}(t+1, n-t+1)$ .



- Note que sin datos muestrales, la media de  $\theta$  basada en la distribución a priori  $E(\theta) = 0,5$ .

- Note que sin datos muestrales, la media de  $\theta$  basada en la distribución a priori  $E(\theta) = 0,5$ .
- Sin embargo, dada la información contenida en una muestra observada, la media a posterior es

$$E(\theta|\mathbf{x}) = \frac{\sum_{i=1}^n x_i + 2}{n + 2} = \frac{n\bar{x} + 1}{n + 2} = \frac{n}{n + 2}\bar{x} + \frac{2}{n + 2} \cdot 0,5$$

- Note que sin datos muestrales, la media de  $\theta$  basada en la distribución a priori  $E(\theta) = 0,5$ .
- Sin embargo, dada la información contenida en una muestra observada, la media a posterior es

$$E(\theta|\mathbf{x}) = \frac{\sum_{i=1}^n x_i + 2}{n + 2} = \frac{n\bar{x} + 1}{n + 2} = \frac{n}{n + 2}\bar{x} + \frac{2}{n + 2} \cdot 0,5$$

- Por ejemplo, para una muestra de  $n = 25$  con  $t = 21$ , la media a posteriori es  $E(\theta|\mathbf{x}) = 0,815$ . Mientras que  $\bar{X} = 0,84$ .

# Estimación Puntual

- Note que sin datos muestrales, la media de  $\theta$  basada en la distribución a priori  $E(\theta) = 0,5$ .
- Sin embargo, dada la información contenida en una muestra observada, la media a posterior es

$$E(\theta|\mathbf{x}) = \frac{\sum_{i=1}^n x_i + 2}{n + 2} = \frac{n\bar{x} + 2}{n + 2} = \frac{n}{n + 2}\bar{x} + \frac{2}{n + 2} \cdot 0,5$$

- Por ejemplo, para una muestra de  $n = 25$  con  $t = 21$ , la media a posteriori es  $E(\theta|\mathbf{x}) = 0,815$ . Mientras que  $\bar{X} = 0,84$ .
- Si tenemos la distribución a posteriori completa, ¿por qué fijarnos solo en la media?

- A continuación responderemos la pregunta: ¿por qué fijarnos solo en la media a posteriori?

- A continuación responderemos la pregunta: ¿por qué fijarnos solo en la media a posteriori?
- Todas las inferencias bayesianas sobre  $\theta$  se basan en la distribución posterior.

- A continuación responderemos la pregunta: ¿por qué fijarnos solo en la media a posteriori?
- Todas las inferencias bayesianas sobre  $\theta$  se basan en la distribución posterior.
- Para cuantificar que tan cerca se encuentra un estimador de  $\theta$  debemos definir una función de pérdida y ponderar sobre todos los valores posible del parámetro.

## Definición (Función de Pérdida)

Para un estimador  $T$  de  $\theta$ , una función de pérdida  $\mathcal{L}(T; \theta)$  es una función de valor real no negativa con tal que  $\mathcal{L}(\theta; \theta) = 0$



## Definición (Función de Pérdida)

Para un estimador  $T$  de  $\theta$ , una función de pérdida  $\mathcal{L}(T; \theta)$  es una función de valor real no negativa con tal que  $\mathcal{L}(\theta; \theta) = 0$

Algunos ejemplos de funciones de pérdidas son,

- i) Pérdida cuadrática,  $\mathcal{L}_2(T; \theta) = (T - \theta)^2$ ,
- ii) Pérdida absoluta,  $\mathcal{L}_1(T; \theta) = |T - \theta|$ ,
- iii) Norma  $L_p$ ,  $\mathcal{L}_p(T; \theta) = |T - \theta|^p$ , para  $p > 0$ .

## Definición (Función de Pérdida)

Para un estimador  $T$  de  $\theta$ , una función de pérdida  $\mathcal{L}(T; \theta)$  es una función de valor real no negativa con tal que  $\mathcal{L}(\theta; \theta) = 0$

Algunos ejemplos de funciones de pérdidas son,

- i) Pérdida cuadrática,  $\mathcal{L}_2(T; \theta) = (T - \theta)^2$ ,
- ii) Pérdida absoluta,  $\mathcal{L}_1(T; \theta) = |T - \theta|$ ,
- iii) Norma  $L_p$ ,  $\mathcal{L}_p(T; \theta) = |T - \theta|^p$ , para  $p > 0$ .

El valor esperado de la función de pérdida, tomado como función de  $\theta$ , es llamado función de riesgo.

## Definición (Función de Riesgo)

Sea  $\mathbf{X} = (X_1, \dots, X_n)$  una muestra aleatoria. Para un estimador  $T(\mathbf{X})$  de  $\theta$  y una función de pérdida  $\mathcal{L}(T; \theta)$ , la función de riesgo asociada con  $T$  y  $\mathcal{L}$  es el valor esperado de la función de pérdida con respecto a  $f(\mathbf{x} | \theta)$ ; la cual denotamos por  $R(T; \theta) = E\{\mathcal{L}(T; \theta) | \theta\}$ .

## Definición (Función de Riesgo)

Sea  $\mathbf{X} = (X_1, \dots, X_n)$  una muestra aleatoria. Para un estimador  $T(\mathbf{X})$  de  $\theta$  y una función de pérdida  $\mathcal{L}(T; \theta)$ , la función de riesgo asociada con  $T$  y  $\mathcal{L}$  es el valor esperado de la función de pérdida con respecto a  $f(\mathbf{x} \mid \theta)$ ; la cual denotamos por  $R(T; \theta) = E\{\mathcal{L}(T; \theta) \mid \theta\}$ .

- Cuando la función de pérdida es la cuadrática, la función de riesgo se denomina error cuadrático medio (MSE) del estimador.

## Definición (Función de Riesgo)

Sea  $\mathbf{X} = (X_1, \dots, X_n)$  una muestra aleatoria. Para un estimador  $T(\mathbf{X})$  de  $\theta$  y una función de pérdida  $\mathcal{L}(T; \theta)$ , la función de riesgo asociada con  $T$  y  $\mathcal{L}$  es el valor esperado de la función de pérdida con respecto a  $f(\mathbf{x} | \theta)$ ; la cual denotamos por  $R(T; \theta) = E\{\mathcal{L}(T; \theta) | \theta\}$ .

- Cuando la función de pérdida es la cuadrática, la función de riesgo se denomina error cuadrático medio (MSE) del estimador.
- Cuando la función de pérdida es la pérdida absoluta, entonces la función de riesgo se conoce como la desviación media absoluta (MAD) del estimador.

- En el enfoque clásico, a menudo se elige un estimador que minimice el valor esperado de la función de pérdida, denominado riesgo del estimador.

- En el enfoque clásico, a menudo se elige un estimador que minimice el valor esperado de la función de pérdida, denominado riesgo del estimador.
- En el enfoque bayesiano, se eligen estimadores que minimicen el valor esperado de la función de riesgo, llamado riesgo de Bayes.

- En el enfoque clásico, a menudo se elige un estimador que minimice el valor esperado de la función de pérdida, denominado riesgo del estimador.
- En el enfoque bayesiano, se eligen estimadores que minimicen el valor esperado de la función de riesgo, llamado riesgo de Bayes.

## Definición (Riesgo de Bayes)

Si  $X_1, \dots, X_n$  es una muestra de  $n$  v.a. iid con fdp común  $f(x|\theta)$ , el riesgo de Bayes de un estimador  $T$  asociado con una función de pérdida  $\mathcal{L}$  y una distribución a priori  $\pi(\theta; \lambda)$  es  $E_{\theta}\{R(T; \theta)\}$ .



## Definición (Estimador de Bayes)

Sea  $\mathcal{L}$  una función de pérdida y  $\pi(\theta; \lambda)$  una distribución a priori para  $\theta$ . Un estimador  $T^*$  de  $\theta$  con mínimo riesgo de Bayes se denomina estimador bayesiano de  $\theta$ .

## Definición (Estimador de Bayes)

Sea  $\mathcal{L}$  una función de pérdida y  $\pi(\theta; \lambda)$  una distribución a priori para  $\theta$ . Un estimador  $T^*$  de  $\theta$  con mínimo riesgo de Bayes se denomina estimador bayesiano de  $\theta$ .

Así,  $T^*$  es el estimador bayesiano de  $\theta$  cuando  $E_{\theta}\{R(T^*; \theta)\} \leq E_{\theta}\{R(T; \theta)\}$  para cualquier otro estimador  $T$  de  $\theta$ .

# Estimación Puntual

## Definición (Estimador de Bayes)

Sea  $\mathcal{L}$  una función de pérdida y  $\pi(\theta; \lambda)$  una distribución a priori para  $\theta$ . Un estimador  $T^*$  de  $\theta$  con mínimo riesgo de Bayes se denomina estimador bayesiano de  $\theta$ .

Así,  $T^*$  es el estimador bayesiano de  $\theta$  cuando  $E_{\theta}\{R(T^*; \theta)\} \leq E_{\theta}\{R(T; \theta)\}$  para cualquier otro estimador  $T$  de  $\theta$ .

## Teorema

Sea  $X_1, \dots, X_n$  una muestra aleatoria con fdp conjunta  $f(\mathbf{x}|\theta)$ ,  $\pi(\theta; \lambda)$  una distribución a priori para  $\theta$ , y  $\mathcal{L}$  una función de pérdida. El estimador de Bayes de  $\theta$  es el estimador  $T^*$  que minimiza

$$\int_{\Theta} \mathcal{L}(T; \theta) f(\theta|\mathbf{x}) \pi(\theta; \lambda) d\theta.$$

A esta cantidad se le denomina riesgo de Bayes a posterior.

Dem. Tenemos que

$$\begin{aligned} E_{\theta}\{R(T; \theta)\} &= \int_{\Theta} \int_{\mathcal{X}} \mathcal{L}(T; \theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\mathbf{x} d\theta \\ &= \int_{\mathcal{X}} \left[ \int_{\Theta} \mathcal{L}(T; \theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta \right] d\mathbf{x} \\ &= \int_{\mathcal{X}} \left[ \int_{\Theta} \mathcal{L}(T; \theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) \frac{f(\mathbf{x})}{f(\mathbf{x})} d\theta \right] d\mathbf{x} \\ &= \int_{\mathcal{X}} \left[ \int_{\Theta} \mathcal{L}(T; \theta) f(\theta|\mathbf{x}) d\theta \right] f(\mathbf{x}) d\mathbf{x}. \end{aligned}$$

Ya que  $\mathcal{L}$  es no negativa, se tiene que  $E_{\theta}\{R(T; \theta)\}$  es mínimo cuando la integral  $\int_{\Theta} \mathcal{L}(T; \theta) f(\theta|\mathbf{x}) d\theta$  sea mínima, para cada  $\mathbf{x}$ .

## Teorema

Si  $X_1, \dots, X_n$  es una muestra de  $n$  va iid con fdp común  $f(x|\theta)$ ,  $\pi(\theta; \lambda)$  es una distribución a priori para  $\theta$ , y  $\mathcal{L}(\hat{\theta}; \theta)$  es la pérdida cuadrática, entonces la media de la distribución posterior,  $E(\theta|x)$ , es el estimador de Bayesiano de  $\theta$ .

## Teorema

Si  $X_1, \dots, X_n$  es una muestra de  $n$  va iid con fdp común  $f(x|\theta)$ ,  $\pi(\theta; \lambda)$  es una distribución a priori para  $\theta$ , y  $\mathcal{L}(\hat{\theta}; \theta)$  es la pérdida cuadrática, entonces la media de la distribución posterior,  $E(\theta|x)$ , es el estimador de Bayesiano de  $\theta$ .

## Teorema

Si  $X_1, \dots, X_n$  es una muestra de variables aleatorias iid con fdp común  $f(x|\theta)$ ,  $\pi(\theta; \lambda)$  es una distribución a priori para  $\theta$ , y  $\mathcal{L}(\hat{\theta}; \theta)$  es la función de pérdida absoluta, entonces la mediana de la distribución posterior es el estimador de Bayes de  $\theta$ .

**Ejemplo:** Sabemos que si  $X_i|\theta \sim P(\theta)$ , y la distribución a priori es  $\text{Exp}(\lambda)$ , la distribución posterior de  $\theta|\mathbf{x}$  es  $\text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$ .

**Ejemplo:** Sabemos que si  $X_i|\theta \sim P(\theta)$ , y la distribución a priori es  $\text{Exp}(\lambda)$ , la distribución posterior de  $\theta|\mathbf{x}$  es Gamma  $\left(\sum_{i=1}^n x_i + 1, \frac{1}{n+\frac{1}{\lambda}}\right)$ . En el caso de pérdida cuadrática,

$$\hat{\theta} = \mathbb{E}(\theta|\mathbf{x}) = \frac{\lambda n}{\lambda n + 1} \bar{x} + \frac{1}{\lambda n + 1} \lambda.$$

Mientras que para la pérdida absoluta, no hay una fórmula cerrada.



# Estimación Puntual

**Ejemplo:** Sabemos que si  $X_i|\theta \sim P(\theta)$ , y la distribución a priori es  $\text{Exp}(\lambda)$ , la distribución posterior de  $\theta|\mathbf{x}$  es  $\text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n+\frac{1}{\lambda}}\right)$ . En el caso de pérdida cuadrática,

$$\hat{\theta} = \mathbb{E}(\theta|\mathbf{x}) = \frac{\lambda n}{\lambda n + 1} \bar{x} + \frac{1}{\lambda n + 1} \lambda.$$

Mientras que para la pérdida absoluta, no hay una fórmula cerrada.

Si  $X_1, \dots, X_{25}$  es una muestra aleatoria con  $\sum_{i=1}^{25} x_i = 52$  y hiperparámetro  $\lambda = 5$ , entonces  $\theta|\mathbf{x} \sim \text{Gamma}(53, 0,04)$ . En este caso, la mediana de la distribución posterior es

$$\begin{aligned} &> \text{qgamma}(0,5, 53, \text{scale} = 0,04) \\ &[1] \quad 2,11 \end{aligned}$$

Para propósitos comparativos, el EMV de  $\theta$  para una distribución Poisson es  $\bar{X}$ , que en este es  $\bar{x} = 2,08$ . Mientras que el estimador de Bayes bajo pérdida cuadrática es  $\hat{\theta} = 2,12$

- La inferencia bayesiana permite la especificación probabilística de creencias previas a través de una distribución a priori.

- La inferencia bayesiana permite la especificación probabilística de creencias previas a través de una distribución a priori.
- A menudo es útil y está justificado restringir el rango de posibles distribuciones a priori a una familia específica con uno o dos parámetros.

- La inferencia bayesiana permite la especificación probabilística de creencias previas a través de una distribución a priori.
- A menudo es útil y está justificado restringir el rango de posibles distribuciones a priori a una familia específica con uno o dos parámetros.
- La elección de esta familia puede basarse en el tipo de función de verosimilitud encontrada.

# Estimación Puntual

- La inferencia bayesiana permite la especificación probabilística de creencias previas a través de una distribución a priori.
- A menudo es útil y está justificado restringir el rango de posibles distribuciones a priori a una familia específica con uno o dos parámetros.
- La elección de esta familia puede basarse en el tipo de función de verosimilitud encontrada.

## Definición (Distribución a priori conjugada)

Sea  $L(\theta) = f(x|\theta)$  una función de verosimilitud basada en la observación  $X = x$ . Una clase  $\mathcal{G}$  de distribuciones se denomina conjugada con respecto a  $L(\theta)$  si la distribución posterior  $f(\theta|x)$  está en  $\mathcal{G}$  para todo  $x$ , siempre que la distribución a priori  $\pi(\theta; \lambda)$  esté en  $\mathcal{G}$ .

# Estimación Puntual

Algunas distribuciones a priori conjugadas para diferentes funciones de verosimilitud, se muestran a continuación:

Verosimilitud	Priori conjugada	Posteriori
$X \mid \pi \sim b(n, \pi)$	$\pi \sim \text{Beta}(\alpha, \beta)$	$\pi \mid x \sim \text{Beta}(\alpha + x, \beta + n - x)$
$X \mid \pi \sim \text{Geo}(\pi)$	$\pi \sim \text{Beta}(\alpha, \beta)$	$\pi \mid x \sim \text{Beta}(\alpha + 1, \beta + x - 1)$
$X \mid \lambda \sim \text{Po}(\lambda)$	$\lambda \sim \text{G}(\alpha, \beta)$	$\lambda \mid x \sim \text{G}(\alpha + x, \beta + e)$
$X \mid \lambda \sim \text{Exp}(\lambda)$	$\lambda \sim \text{G}(\alpha, \beta)$	$\lambda \mid x \sim \text{G}(\alpha + 1, \beta + x)$
$X \mid \mu \sim \text{N}(\mu, \sigma^2 \text{ conocida})$	$\mu \sim \text{N}(v, \tau^2)$	ver Ec. (1.1) abajo
$X \mid \sigma^2 \sim \text{N}(\mu \text{ conocida}, \sigma^2)$	$\sigma^2 \sim \text{IG}(\alpha, \beta)$	$\sigma^2 \mid x \sim \text{IG}\left(\alpha + \frac{1}{2}, \beta + \frac{1}{2}(x - \mu)^2\right)$

$$\mu \mid x \sim \text{N} \left( \left( \frac{1}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1} \left( \frac{x}{\sigma^2} + \frac{v}{\tau^2} \right), \left( \frac{1}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1} \right) \quad (1)$$

# Estimación Puntual

Algunas distribuciones a priori conjugadas para diferentes funciones de verosimilitud, se muestran a continuación:

Verosimilitud	Priori conjugada	Posteriori
$X \mid \pi \sim b(n, \pi)$	$\pi \sim \text{Beta}(\alpha, \beta)$	$\pi \mid x \sim \text{Beta}(\alpha + x, \beta + n - x)$
$X \mid \pi \sim \text{Geo}(\pi)$	$\pi \sim \text{Beta}(\alpha, \beta)$	$\pi \mid x \sim \text{Beta}(\alpha + 1, \beta + x - 1)$
$X \mid \lambda \sim \text{Po}(\lambda)$	$\lambda \sim \text{G}(\alpha, \beta)$	$\lambda \mid x \sim \text{G}(\alpha + x, \beta + e)$
$X \mid \lambda \sim \text{Exp}(\lambda)$	$\lambda \sim \text{G}(\alpha, \beta)$	$\lambda \mid x \sim \text{G}(\alpha + 1, \beta + x)$
$X \mid \mu \sim N(\mu, \sigma^2 \text{ conocida})$	$\mu \sim N(v, \tau^2)$	ver Ec. (1.1) abajo
$X \mid \sigma^2 \sim N(\mu \text{ conocida}, \sigma^2)$	$\sigma^2 \sim \text{IG}(\alpha, \beta)$	$\sigma^2 \mid x \sim \text{IG}\left(\alpha + \frac{1}{2}, \beta + \frac{1}{2}(x - \mu)^2\right)$

$$\mu \mid x \sim N \left( \left( \frac{1}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1} \left( \frac{x}{\sigma^2} + \frac{v}{\tau^2} \right), \left( \frac{1}{\sigma^2} + \frac{1}{\tau^2} \right)^{-1} \right) \quad (1)$$

Si bien matemáticamente esto es muy conveniente, si una familia conjugada es una opción razonable para un problema particular, es una cuestión que debe dejarse al experimentador.

# Estimación Puntual

Una alternativa para no sesgar los resultados con la elección de la distribución a priori, es utilizar una priori no informativa.



Una alternativa para no sesgar los resultados con la elección de la distribución a priori, es utilizar una priori no informativa.

Jeffreys introdujo una distribución a priori con la propiedad de invarianza.

# Estimación Puntual

Una alternativa para no sesgar los resultados con la elección de la distribución a priori, es utilizar una priori no informativa.

Jeffreys introdujo una distribución a priori con la propiedad de invarianza.

## Definición (Priori de Jeffreys)

La distribución a priori de Jeffreys es una distribución proporcional a la raíz de la información de Fisher, es decir

$$\pi(\theta) \propto \sqrt{\mathcal{I}(\theta)}$$

# Estimación Puntual

Una alternativa para no sesgar los resultados con la elección de la distribución a priori, es utilizar una priori no informativa.

Jeffreys introdujo una distribución a priori con la propiedad de invarianza.

## Definición (Priori de Jeffreys)

La distribución a priori de Jeffreys es una distribución proporcional a la raíz de la información de Fisher, es decir

$$\pi(\theta) \propto \sqrt{\mathcal{I}(\theta)}$$

- La distribución a priori de Jeffreys es invariante en el sentido de que la inferencia no depende de la escala elegida para el parámetro.

# Estimación Puntual

Una alternativa para no sesgar los resultados con la elección de la distribución a priori, es utilizar una priori no informativa.

Jeffreys introdujo una distribución a priori con la propiedad de invarianza.

## Definición (Priori de Jeffreys)

La distribución a priori de Jeffreys es una distribución proporcional a la raíz de la información de Fisher, es decir

$$\pi(\theta) \propto \sqrt{\mathcal{I}(\theta)}$$

- La distribución a priori de Jeffreys es invariante en el sentido de que la inferencia no depende de la escala elegida para el parámetro.
- El problema es que no funciona adecuadamente para parámetros multivariantes.

# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.

# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.
- Siempre se tiene,

$$f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda).$$

# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.
- Siempre se tiene,

$$f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda).$$

- Para el caso de pérdida cuadrática el estimador de  $h(\theta)$  es

$$\mathbb{E}[h(\theta)|\mathbf{x}] = \frac{\int_{\Theta} h(\theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}{\int_{\Theta} f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}.$$

# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.

- Siempre se tiene,

$$f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda).$$

- Para el caso de pérdida cuadrática el estimador de  $h(\theta)$  es

$$\mathbb{E}[h(\theta)|\mathbf{x}] = \frac{\int_{\Theta} h(\theta)f(\mathbf{x}|\theta)\pi(\theta; \lambda)d\theta}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta; \lambda)d\theta}.$$

- Como se puede apreciar la dificultad en los métodos bayesianos es el cálculo de una integral.



# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.

- Siempre se tiene,

$$f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda).$$

- Para el caso de pérdida cuadrática el estimador de  $h(\theta)$  es

$$\mathbb{E}[h(\theta)|\mathbf{x}] = \frac{\int_{\Theta} h(\theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}{\int_{\Theta} f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}.$$

- Como se puede apreciar la dificultad en los métodos bayesianos es el cálculo de una integral.
- A continuación veremos algunas alternativas para estimar de forma numérica dichas integrales.

# Métodos Numéricos para Estimadores Bayesianos

- Sabemos que los estimadores Bayesianos dependen de la distribución a priori y de la distribución condicional de los datos.

- Siempre se tiene,

$$f(\theta|\mathbf{x}) \propto L(\theta)\pi(\theta; \lambda).$$

- Para el caso de pérdida cuadrática el estimador de  $h(\theta)$  es

$$\mathbb{E}[h(\theta)|\mathbf{x}] = \frac{\int_{\Theta} h(\theta) f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}{\int_{\Theta} f(\mathbf{x}|\theta) \pi(\theta; \lambda) d\theta}.$$

- Como se puede apreciar la dificultad en los métodos bayesianos es el cálculo de una integral.
- A continuación veremos algunas alternativas para estimar de forma numérica dichas integrales.
- Estas se basan principalmente en simular números aleatorios de la densidad posterior.

- El objetivo del algoritmo Metropolis-Hasting es obtener numeros aleatorios desde una densidad de probabilidad.

- El objetivo del algoritmo Metropolis-Hasting es obtener numeros aleatorios desde una densidad de probabilidad.
- En este sentido, el algoritmo de Metropolis-Hasting, se utiliza en los métodos de estimación bayesiano, simulando números aleatorios de la distribución posterior.

- El objetivo del algoritmo Metropolis-Hasting es obtener numeros aleatorios desde una densidad de probabilidad.
- En este sentido, el algoritmo de Metropolis-Hasting, se utiliza en los métodos de estimación bayesiano, simulando números aleatorios de la distribución posterior.
- Metropolis-Hasting utiliza cadena de Markov (MCMC) en conjunto de algoritmo de aceptación-rechazo.

- El objetivo del algoritmo Metropolis-Hasting es obtener numeros aleatorios desde una densidad de probabilidad.
- En este sentido, el algoritmo de Metropolis-Hasting, se utiliza en los métodos de estimación bayesiano, simulando números aleatorios de la distribución posterior.
- Metropolis-Hasting utiliza cadena de Markov (MCMC) en conjunto de algoritmo de aceptación-rechazo.
- La idea principal de los algoritmos de aceptación-rechazo, se basa en definir un criterio para aceptar o rechazar si un número aleatorio simulado de otra densidad es factible que sea de la densidad objetivo.

# Metropolis-Hasting

## Aceptación - Rechazo

- Suponga que se quiere simular desde  $f(\theta | x)$  sin necesariamente conocer la constante de integración.

# Metropolis-Hasting

## Aceptación - Rechazo

- Suponga que se quiere simular desde  $f(\theta | x)$  sin necesariamente conocer la constante de integración.
- El primer paso en el algoritmo de aceptación-rechazo, consiste en encontrar una densidad  $p(\theta)$  tal que:
  - Sea fácil de simular,
  - La densidad  $p$  se asemeja a la densidad posterior de interés  $f$  en términos de localización y dispersión,
  - Para todo  $\theta$ , se tiene que  $f(\theta | x) \leq cp(\theta)$ .



# Metropolis-Hasting

## Aceptación - Rechazo

- Suponga que se quiere simular desde  $f(\theta | x)$  sin necesariamente conocer la constante de integración.
- El primer paso en el algoritmo de aceptación-rechazo, consiste en encontrar una densidad  $p(\theta)$  tal que:
  - Sea fácil de simular,
  - La densidad  $p$  se asemeja a la densidad posterior de interés  $f$  en términos de localización y dispersión,
  - Para todo  $\theta$ , se tiene que  $f(\theta | x) \leq cp(\theta)$ .
- Luego de definir la fdp  $p$ , el algoritmo de aceptación-rechazo sigue como:
  - 1 Simular independientemente  $\theta \sim p(\theta)$  y  $U \sim U(0, 1)$ .
  - 2 Si  $cUp(\theta) \leq f(\theta | x)$ , entonces acepte  $\theta$  como una extracción de la densidad posterior  $f$ ; en caso contrario, rechace  $\theta$ .
  - 3 Continuar los pasos 1 y 2 hasta que se haya recogido un número suficiente número de  $\theta$  aceptados.

- La estrategia de muestreo MCMC establece una cadena de Markov irreducible y aperiódica donde la distribución estacionaria es igual a la distribución posterior de interés.

- La estrategia de muestreo MCMC establece una cadena de Markov irreducible y aperiódica donde la distribución estacionaria es igual a la distribución posterior de interés.
- Un algoritmo de Metropolis-Hastings comienza con un valor inicial  $\theta^0$  y genera una secuencia  $\theta^t$  dado el valor de  $\theta^{t-1}$  a través de una regla.

- La estrategia de muestreo MCMC establece una cadena de Markov irreducible y aperiódica donde la distribución estacionaria es igual a la distribución posterior de interés.
- Un algoritmo de Metropolis-Hastings comienza con un valor inicial  $\theta^0$  y genera una secuencia  $\theta^t$  dado el valor de  $\theta^{t-1}$  a través de una regla.
- Esta regla consiste en simular un valor candidato  $\theta^*$  de una densidad de propuesta  $p$ , y además del cálculo de una probabilidad de aceptación  $\alpha$ , que indica la probabilidad de que el valor candidato sea aceptado como el siguiente valor de la secuencia.

- La estrategia de muestreo MCMC establece una cadena de Markov irreducible y aperiódica donde la distribución estacionaria es igual a la distribución posterior de interés.
- Un algoritmo de Metropolis-Hastings comienza con un valor inicial  $\theta^0$  y genera una secuencia  $\theta^t$  dado el valor de  $\theta^{t-1}$  a través de una regla.
- Esta regla consiste en simular un valor candidato  $\theta^*$  de una densidad de propuesta  $p$ , y además del cálculo de una probabilidad de aceptación  $\alpha$ , que indica la probabilidad de que el valor candidato sea aceptado como el siguiente valor de la secuencia.
- El algoritmo Metropolis-Hasting puede describirse como sigue:

❶ Simular  $\theta^* \sim p(\theta^* \mid \theta^{t-1})$ .

❷ Calcular el radio

$$R = \frac{f(\theta^* \mid x)p(\theta^{t-1} \mid \theta^*)}{f(\theta^{t-1} \mid x)p(\theta^* \mid \theta^{t-1})}$$

❸ Calcular la probabilidad de aceptación

$$\alpha = \min\{R, 1\}$$

❹ Simular  $U \sim U(0, 1)$ ; luego comparar  $\alpha$  y  $U$ , de modo que:

$$\text{Si } U \leq \alpha \Rightarrow \theta^t = \theta^* \quad \text{si no } \theta^t = \theta^{t-1}$$

# Métodos Numéricos para Estimadores Bayesianos

- Existen varios otros métodos numéricos, como Importance Sample o Gibbs Sample.

# Métodos Numéricos para Estimadores Bayesianos

- Existen varios otros métodos numéricos, como Importance Sample o Gibbs Sample.
- Volviendo al objetivo de estimador de bayes, y asumiendo que  $\theta^1, \theta^2, \dots, \theta^n$  es una muestra aleatoria desde la distribución porterior  $f(\theta | x)$ , entonces, el estimador de bayes de  $\theta$  es

$$\hat{\theta}_B = \frac{1}{n} \sum_{i=1}^n \theta^i \quad \text{bajo pérdida cuadrática}$$

$$\hat{\theta}_B = \theta^{((n+1)/2)} \quad \text{bajo pérdida absoluta}$$



Una región de credibilidad bayesiana es un estimador de intervalo basado en la distribución posterior.

Una región de credibilidad bayesiana es un estimador de intervalo basado en la distribución posterior.

## Definición

Sea  $X_1, \dots, X_n$  una muestra aleatoria y  $f(\theta|\mathbf{x})$  la distribución posterior de  $\theta$  para una priori  $\pi(\theta; \lambda)$ . Un estimador de intervalo  $[T_1, T_2]$  es un intervalo de credibilidad bayesiano del  $100(1 - \alpha)\%$  para  $\theta$  si

$$P(T_1 \leq \theta \leq T_2|\mathbf{x}) = \int_{t_1}^{t_2} f(\theta|\mathbf{x})d\theta = 1 - \alpha$$

**Ejemplo:** Sea  $X_1, \dots, X_n$  una muestra de va iid  $P(\theta)$  y  $\theta \sim \text{Exp}(\lambda)$  la distribución a priori. La distribución posterior es

$$\theta|\mathbf{x} \sim \text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$$

**Ejemplo:** Sea  $X_1, \dots, X_n$  una muestra de va iid  $P(\theta)$  y  $\theta \sim \text{Exp}(\lambda)$  la distribución a priori. La distribución posterior es

$$\theta | \mathbf{x} \sim \text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$$

Así un IC (de credibilidad) del  $100(1 - \alpha)\%$  para  $\theta$  es  $[t_{\alpha/2}, t_{1-\alpha/2}]$  donde  $t_{\alpha/2}$  y  $t_{1-\alpha/2}$  son los cuantiles  $\alpha/2$  y  $1 - \alpha/2$  de la distribución  $\text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$ .

**Ejemplo:** Sea  $X_1, \dots, X_n$  una muestra de va iid  $P(\theta)$  y  $\theta \sim \text{Exp}(\lambda)$  la distribución a priori. La distribución posterior es

$$\theta|\mathbf{x} \sim \text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$$

Así un IC (de credibilidad) del  $100(1 - \alpha)\%$  para  $\theta$  es  $[t_{\alpha/2}, t_{1-\alpha/2}]$  donde  $t_{\alpha/2}$  y  $t_{1-\alpha/2}$  son los cuantiles  $\alpha/2$  y  $1 - \alpha/2$  de la distribución  $\text{Gamma}\left(\sum_{i=1}^n x_i + 1, \frac{1}{n + \frac{1}{\lambda}}\right)$ .

Por ejemplo, si,  $n = 25$ ,  $\sum_{i=1}^{25} x_i = 112$ , y  $\lambda = 2$ , la distribución posterior es  $\text{Gamma}(113, 0,0392)$ , y un IC del 95 % para  $\theta$  es  $[3,65, 5,28]$ .

- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.

¿Alguna Consulta?