

# EPG3343 - Seminario de Estadística III

## Clase 10

Jonathan Acosta

Pontificia Universidad Católica de Chile

Segundo Semestre, 2022



- 1 INLA: Integrated Nested Laplace Approximations
  - Inferencia bayesiana aproximada con INLA
  
- 2 Regresión Bayesianos
  - Modelos de Regresión
  - Predicción

## 1 INLA: Integrated Nested Laplace Approximations

- Inferencia bayesiana aproximada con INLA

## 2 Regresión Bayesianos

- Modelos de Regresión
- Predicción

- El algoritmo INLA, propuesto por Rue et al.(2009), es un algoritmo determinista para la inferencia bayesiana.

- El algoritmo INLA, propuesto por Rue et al.(2009), es un algoritmo determinista para la inferencia bayesiana.
- A diferencia de los métodos de simulación, tales como MCMC, el INLA es especialmente diseñado para modelos latentes Gaussianos.

- El algoritmo INLA, propuesto por Rue et al.(2009), es un algoritmo determinista para la inferencia bayesiana.
- A diferencia de los métodos de simulación, tales como MCMC, el INLA es especialmente diseñado para modelos latentes Gaussianos.
- Comparado con el MCMC proporciona precisión en menor tiempo de computo.

## La Aproximación de Laplace

## La Aproximación de Laplace

- Suponga que el interés es calcular

$$\int f(x)dx = \int \exp(\log(f(x)))dx$$



## La Aproximación de Laplace

- Suponga que el interés es calcular

$$\int f(x)dx = \int \exp(\log(f(x)))dx$$

- Considere la aproximación de Taylor de orden 2 de  $\log(f(x))$  en  $x = x_0$ , es decir,

$$\log(f(x)) \approx \log(f(x_0)) + \frac{\partial f(x_0)}{\partial x}(x - x_0) + \frac{\partial^2 f(x_0)}{2\partial x}(x - x_0)^2$$

## La Aproximación de Laplace

- Suponga que el interés es calcular

$$\int f(x)dx = \int \exp(\log(f(x)))dx$$

- Considere la aproximación de Taylor de orden 2 de  $\log(f(x))$  en  $x = x_0$ , es decir,

$$\log(f(x)) \approx \log(f(x_0)) + \frac{\partial f(x_0)}{\partial x}(x - x_0) + \frac{\partial^2 f(x_0)}{2\partial x}(x - x_0)^2$$

- Si  $x_0$  corresponde a la moda de  $\log(f(x))$ , denotada por  $x^*$  entonces

$$\log(f(x)) \approx \log(f(x^*)) + \frac{\partial^2 f(x^*)}{2\partial x}(x - x^*)^2$$

## La Aproximación de Laplace

- Suponga que el interés es calcular

$$\int f(x)dx = \int \exp(\log(f(x)))dx$$

- Considere la aproximación de Taylor de orden 2 de  $\log(f(x))$  en  $x = x_0$ , es decir,

$$\log(f(x)) \approx \log(f(x_0)) + \frac{\partial f(x_0)}{\partial x}(x - x_0) + \frac{\partial^2 f(x_0)}{2\partial x}(x - x_0)^2$$

- Si  $x_0$  corresponde a la moda de  $\log(f(x))$ , denotada por  $x^*$  entonces

$$\log(f(x)) \approx \log(f(x^*)) + \frac{\partial^2 f(x^*)}{2\partial x}(x - x^*)^2$$

- Luego, la integral original se puede aproximar mediante

$$\int f(x)dx \approx \exp(\log(f(x^*)) \int \exp\left(-\frac{(x-x^*)^2}{2\sigma^{2*}}\right) dx$$

$$\text{donde } \sigma^{2*} = -\left(\frac{\partial^2 f(x^*)}{2\partial x}\right)^{-1}.$$

- Luego, la integral original se puede aproximar mediante

$$\int f(x)dx \approx \exp(\log(f(x^*)) \int \exp\left(-\frac{(x-x^*)^2}{2\sigma^{2*}}\right) dx$$

$$\text{donde } \sigma^{2*} = -\left(\frac{\partial^2 f(x^*)}{2\partial x}\right)^{-1}.$$

- Es decir, la integral se puede aproximar por una distribución Normal de media  $x^*$  y varianza  $\sigma^{2*}$ .

- Luego, la integral original se puede aproximar mediante

$$\int f(x)dx \approx \exp(\log(f(x^*)) \int \exp\left(-\frac{(x-x^*)^2}{2\sigma^{2*}}\right) dx$$

$$\text{donde } \sigma^{2*} = -\left(\frac{\partial^2 f(x^*)}{2\partial x}\right)^{-1}.$$

- Es decir, la integral se puede aproximar por una distribución Normal de media  $x^*$  y varianza  $\sigma^{2*}$ .
- Si la integral esta definida en  $(\alpha, \beta)$  entonces

$$\int_{\alpha}^{\beta} f(x)dx \approx \sqrt{2\pi\sigma^{2*}} f(x^*) [\Phi(\beta) - \Phi(\alpha)]$$

Por ejemplo, para  $X \sim \text{Gamma}(a, b)$  con densidad

$$f(x) = \frac{b^a}{\Gamma(a)} x^{a-1} \exp(-bx)$$

se tiene que

$$\begin{aligned}\log(f(x)) &= (a-1)\log(x) - bx + \text{cte} \\ \frac{\partial \log(f(x))}{\partial x} &= \frac{a-1}{x} - b \\ \frac{\partial^2 \log(f(x))}{\partial x^2} &= -\frac{a-1}{x^2}.\end{aligned}$$

Obteniendo para  $a > 1$ ,

$$x^* = \frac{a-1}{b} \quad \wedge \quad \sigma^{2*} = \frac{a-1}{b^2}$$

- En el contexto bayesiano se asume que

$$\mathbf{y} \mid \boldsymbol{\theta} \sim p(\mathbf{y} \mid \boldsymbol{\theta}\boldsymbol{\psi}) = \prod_{i=1}^n p(y_i \mid \theta_i, \boldsymbol{\psi})$$

$$\boldsymbol{\theta} \mid \boldsymbol{\psi} \sim p(\boldsymbol{\theta} \mid \boldsymbol{\psi})$$

$$\boldsymbol{\psi} \sim p(\boldsymbol{\psi})$$



- En el contexto bayesiano se asume que

$$\mathbf{y} \mid \boldsymbol{\theta} \sim p(\mathbf{y} \mid \boldsymbol{\theta}\boldsymbol{\psi}) = \prod_{i=1}^n p(y_i \mid \theta_i, \boldsymbol{\psi})$$

$$\boldsymbol{\theta} \mid \boldsymbol{\psi} \sim p(\boldsymbol{\theta} \mid \boldsymbol{\psi})$$

$$\boldsymbol{\psi} \sim p(\boldsymbol{\psi})$$

- Donde  $\boldsymbol{\theta}$  representa los parámetros de las covariables u otros efectos.

- En el contexto bayesiano se asume que

$$\mathbf{y} \mid \boldsymbol{\theta} \sim p(\mathbf{y} \mid \boldsymbol{\theta}\boldsymbol{\psi}) = \prod_{i=1}^n p(y_i \mid \theta_i, \boldsymbol{\psi})$$

$$\boldsymbol{\theta} \mid \boldsymbol{\psi} \sim p(\boldsymbol{\theta} \mid \boldsymbol{\psi})$$

$$\boldsymbol{\psi} \sim p(\boldsymbol{\psi})$$

- Donde  $\boldsymbol{\theta}$  representa los parámetros de las covariables u otros efectos.
- Se asumirá que la distribución a priori de  $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, Q^{-1}(\boldsymbol{\psi}))$ , es decir,  $Q(\boldsymbol{\psi})$  es la matriz de precisión.

- Se asumirá que las componentes de  $\boldsymbol{\theta}$  son condicionalmente independientes, es decir,

$$p(\theta_i, \theta_j \mid \boldsymbol{\theta}_{-(ij)}) = p(\theta_i \mid \boldsymbol{\theta}_{-(ij)})p(\theta_j \mid \boldsymbol{\theta}_{-(ij)})$$

- Se asumirá que las componentes de  $\boldsymbol{\theta}$  son condicionalmente independientes, es decir,

$$p(\theta_i, \theta_j \mid \boldsymbol{\theta}_{-(ij)}) = p(\theta_i \mid \boldsymbol{\theta}_{-(ij)})p(\theta_j \mid \boldsymbol{\theta}_{-(ij)})$$

- Esta especificación es conocida como *Gaussian Markov random field*.

- Se asumirá que las componentes de  $\boldsymbol{\theta}$  son condicionalmente independientes, es decir,

$$p(\theta_i, \theta_j \mid \boldsymbol{\theta}_{-(ij)}) = p(\theta_i \mid \boldsymbol{\theta}_{-(ij)})p(\theta_j \mid \boldsymbol{\theta}_{-(ij)})$$

- Esta especificación es conocida como *Gaussian Markov random field*.
- Luego,

$$\begin{aligned} p(\boldsymbol{\theta}, \boldsymbol{\psi} \mid \mathbf{y}) &\propto p(\boldsymbol{\psi})p(\boldsymbol{\theta} \mid \boldsymbol{\psi})p(\mathbf{y} \mid \boldsymbol{\theta}, \boldsymbol{\psi}) \\ &\propto p(\boldsymbol{\psi})\sqrt{|Q(\boldsymbol{\psi})|} \exp \left( -\frac{1}{2} \boldsymbol{\theta}^\top Q(\boldsymbol{\psi}) \boldsymbol{\theta} \right. \\ &\quad \left. + \sum_{i=1}^n \log(p(y_i \mid \theta_i, \boldsymbol{\psi})) \right) \end{aligned}$$

## 1 INLA: Integrated Nested Laplace Approximations

- Inferencia bayesiana aproximada con INLA

## 2 Regresión Bayesianos

- Modelos de Regresión
- Predicción

- Sea  $\mathbf{y} = (y_1, \dots, y_n)$  un vector de  $n$  observaciones (respuestas).

# Regresión Lineal Bayesiana

- Sea  $\mathbf{y} = (y_1, \dots, y_n)$  un vector de  $n$  observaciones (respuestas).
- Sea  $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_M)$  la matriz de diseño de orden  $n \times (M + 1)$ .



# Regresión Lineal Bayesiana

- Sea  $\mathbf{y} = (y_1, \dots, y_n)$  un vector de  $n$  observaciones (respuestas).
- Sea  $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_M)$  la matriz de diseño de orden  $n \times (M + 1)$ .
- El modelo de regresión lineal asume que

$$y_i \sim \mathcal{N}(\mu_i, \sigma^2) \quad \text{donde} \quad \mu_i = \beta_0 + \sum_{j=1}^M \beta_j X_{ij}$$

# Regresión Lineal Bayesiana

- Sea  $\mathbf{y} = (y_1, \dots, y_n)$  un vector de  $n$  observaciones (respuestas).
- Sea  $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_M)$  la matriz de diseño de orden  $n \times (M + 1)$ .
- El modelo de regresión lineal asume que

$$y_i \sim \mathcal{N}(\mu_i, \sigma^2) \quad \text{donde} \quad \mu_i = \beta_0 + \sum_{j=1}^M \beta_j X_{ij}$$

- Equivalentemente,

$$\mathbb{E}[Y_i \mid \boldsymbol{\beta}, \mathbf{x}_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

# Regresión Lineal Bayesiana

- Sea  $\mathbf{y} = (y_1, \dots, y_n)$  un vector de  $n$  observaciones (respuestas).
- Sea  $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_M)$  la matriz de diseño de orden  $n \times (M + 1)$ .
- El modelo de regresión lineal asume que

$$y_i \sim \mathcal{N}(\mu_i, \sigma^2) \quad \text{donde} \quad \mu_i = \beta_0 + \sum_{j=1}^M \beta_j X_{ij}$$

- Equivalentemente,

$$\mathbb{E}[Y_i \mid \boldsymbol{\beta}, \mathbf{x}_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- En el enfoque clásico  $\boldsymbol{\beta}$  y  $\sigma^2$  son constantes y se estiman mediante máxima verosimilitud.

- Ahora en el enfoque bayesiano se asumirá que  $\beta$  y  $\sigma^2$  son variables aleatorias, por lo que, debemos asignar una distribución priori.

- Ahora en el enfoque bayesiano se asumirá que  $\beta$  y  $\sigma^2$  son variables aleatorias, por lo que, debemos asignar una distribución priori.
- Por ejemplo, una típica elección es

$$\begin{aligned}\beta_j &\sim \mathcal{N}(0, 10^6), \quad j = 1, \dots, M \\ \log(\tau) = \log(1/\sigma^2) &\sim \text{logGamma}(1, 10^{-5})\end{aligned}$$

- Ahora en el enfoque bayesiano se asumirá que  $\beta$  y  $\sigma^2$  son variables aleatorias, por lo que, debemos asignar una distribución priori.
- Por ejemplo, una típica elección es

$$\begin{aligned}\beta_j &\sim \mathcal{N}(0, 10^6), \quad j = 1, \dots, M \\ \log(\tau) = \log(1/\sigma^2) &\sim \text{logGamma}(1, 10^{-5})\end{aligned}$$

- El objetivo es obtener la distribución posterior de  $\beta$  y  $\sigma^2$

# Regresión Lineal Bayesiana

- Asumiendo prioris no informativa en  $\beta$  y  $\sigma^2$ ,

$$p(\beta_j) = 1, \quad j = 1, \dots, M, \quad \wedge \quad p(\log(\sigma^2)) = 1.$$

# Regresión Lineal Bayesiana

- Asumiendo prioris no informativa en  $\boldsymbol{\beta}$  y  $\sigma^2$ ,

$$p(\beta_j) = 1, \quad j = 1, \dots, M, \quad \wedge \quad p(\log(\sigma^2)) = 1.$$

- La distribución posterior de  $\boldsymbol{\beta}$  es una normal multivariada:

$$\boldsymbol{\beta} \mid \sigma^2, \mathbf{y}, \mathbf{X} \sim \mathcal{N}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$$



# Regresión Lineal Bayesiana

- Asumiendo prioris no informativa en  $\beta$  y  $\sigma^2$ ,

$$p(\beta_j) = 1, \quad j = 1, \dots, M, \quad \wedge \quad p(\log(\sigma^2)) = 1.$$

- La distribución posterior de  $\beta$  es una normal multivariada:

$$\beta \mid \sigma^2, \mathbf{y}, \mathbf{X} \sim \mathcal{N}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$$

- Como esta posterior depende de  $\sigma^2$ , integrando obtenemos la distribución marginal posterior de  $\beta_j$ , es decir,

$$p(\beta_j \mid \mathbf{y}, \mathbf{X}) = \int_0^\infty p(\beta_j \mid \sigma^2, \mathbf{y}, \mathbf{X}) d\sigma^2$$

# Regresión Lineal Bayesiana

- Asumiendo prioris no informativa en  $\beta$  y  $\sigma^2$ ,

$$p(\beta_j) = 1, \quad j = 1, \dots, M, \quad \wedge \quad p(\log(\sigma^2)) = 1.$$

- La distribución posterior de  $\beta$  es una normal multivariada:

$$\beta \mid \sigma^2, \mathbf{y}, \mathbf{X} \sim \mathcal{N}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$$

- Como esta posterior depende de  $\sigma^2$ , integrando obtenemos la distribución marginal posterior de  $\beta_j$ , es decir,

$$p(\beta_j \mid \mathbf{y}, \mathbf{X}) = \int_0^\infty p(\beta_j \mid \sigma^2, \mathbf{y}, \mathbf{X}) d\sigma^2$$

- Esto nos lleva a,

$$\beta_j \mid \mathbf{y}, \mathbf{X} \sim t_{n-M}(\hat{\beta}_j, se(\hat{\beta}_j)^2)$$

donde  $\hat{\beta}_j$  es EMV de  $\beta_j$  y  $se(\hat{\beta}_j)$  su respectiva desviación estándar.

- La regresión lineal es un caso particular de los modelos lineales generalizados, donde se asume que  $Y_i$  pertenece a la familia exponencial.

- La regresión lineal es un caso particular de los modelos lineales generalizados, donde se asume que  $Y_i$  pertenece a la familia exponencial.
- Si  $\eta$  representa el parámetro natural de la familia exponencial, entonces se asume que

$$\eta_i = g(\mu_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- La regresión lineal es un caso particular de los modelos lineales generalizados, donde se asume que  $Y_i$  pertenece a la familia exponencial.
- Si  $\eta$  representa el parámetro natural de la familia exponencial, entonces se asume que

$$\eta_i = g(\mu_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- Por ejemplo, en el caso binomial (Bernoulli) se tiene que

$$Y_i \sim \text{Bin}(n_i, \pi_i)$$

$$\eta_i = \text{logit}(\pi_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- La regresión lineal es un caso particular de los modelos lineales generalizados, donde se asume que  $Y_i$  pertenece a la familia exponencial.
- Si  $\eta$  representa el parámetro natural de la familia exponencial, entonces se asume que

$$\eta_i = g(\mu_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- Por ejemplo, en el caso binomial (Bernoulli) se tiene que

$$Y_i \sim \text{Bin}(n_i, \pi_i)$$

$$\eta_i = \text{logit}(\pi_i) = \beta_0 + \sum_{j=1}^M \beta_j X_{ij} = \mathbf{X}\boldsymbol{\beta}$$

- Finalmente se asume una distribución a priori para  $\beta_0, \beta_1, \dots, \beta_M$ , la cual típicamente es una Normal con varianza grande.

- Suponga que  $y^*$  representa un valor futuro o nuevo.

- Suponga que  $y^*$  representa un valor futuro o nuevo.
- Así, la densidad de esta nueva observación, dada la muestra queda como:

$$\begin{aligned} p(y^* | \mathbf{y}) &= \frac{p(\mathbf{y}, y^*)}{p(\mathbf{y})} \\ &= \frac{1}{p(\mathbf{y})} \int p(y^* | \boldsymbol{\theta}) p(\mathbf{y} | \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta} \\ &= \frac{1}{p(\mathbf{y})} \int p(y^* | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathbf{y}) p(\mathbf{y}) d\boldsymbol{\theta} \\ &= \int p(y^* | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathbf{y}) d\boldsymbol{\theta} \end{aligned}$$



- Banerjee S., Carlin B., and Gelfand A. (2015) *Hierarchical Modeling and Analysis for Spatial Data*, Boca Raton: Chapman Hall/CRC.
- Cressie, N. (1993) *Statistics for Spatial Data*. New York: Wiley.
- Matheron, G., (1965) Les variables régionalisés et leur estimation. Masson, Paris.
- Shabenberger, O., Gotway, C. A. (2005) *Statistical Methods for Spatial Data Analysis*. Boca Raton, FL: Chapman & Hall/CRC.

¿Alguna Consulta?