

Introducción al Modelamiento Espacio-Temporal

Jonathan Acosta

2022-11-16

Procesos Espacio-Temporal

Sea $\{Z(\mathbf{s}, t)\}$ con $\mathbf{s} \in D \subset \mathbb{R}^d$ y $t \in \mathbb{Z}^+$ un proceso espacio-temporal de media

$$\mu(\mathbf{s}, t) = \mathbb{E}[Z(\mathbf{s}, t)]$$

y función de covarianza

$$C(\mathbf{s}_1, \mathbf{s}_2, t_1, t_2) = \text{cov}(Z(\mathbf{s}_1, t_1), Z(\mathbf{s}_2, t_2)).$$

Diremos que el proceso $\{Z(\mathbf{s}, t)\}$ es débilmente estacionario de media μ y función de covarianza $C^0(\mathbf{h}, u)$ si

$$\mu(\mathbf{s}, t) = \mu \quad (\text{cte.}), \quad \forall \mathbf{s}, t \quad \wedge \quad C(\mathbf{s}_1, \mathbf{s}_2, t_1, t_2) = C^0(\mathbf{h}, u), \quad \mathbf{h} = \mathbf{s}_2 - \mathbf{s}_1, \quad u = t_2 - t_1.$$

Es decir, la función de covarianza depende exclusivamente de la diferencia espacial y temporal. Considerando un abuso de notación escribiremos simplemente $C^0(\mathbf{h}, u) = C(\mathbf{h}, u)$.

Análogo, al caso espacial, se define el semivariograma como

$$\gamma(\mathbf{h}, u) = \mathbb{V}[Z(\mathbf{s} + \mathbf{h}, t + u) - Z(\mathbf{s}, t)] = C(\mathbf{0}, 0) - C(\mathbf{h}, u)$$

Estimadores empíricos

Sea $\mathbf{Z}_{n,T} = Z(\mathbf{s}_i, t_j)$ para $i = 1, \dots, n$ y $j = 1, \dots, T$, se define el estimador de momentos del variograma y la covianza como

$$\hat{\gamma}(\mathbf{h}, u) = \frac{1}{2|N(\mathbf{h}, u)|} \sum_{N(\mathbf{h}, u)} [Z(\mathbf{s}_i, t_i) - Z(\mathbf{s}_j, t_j)]^2$$
$$\hat{C}(\mathbf{h}, u) = \frac{1}{2|N(\mathbf{h}, u)|} \sum_{N(\mathbf{h}, u)} [Z(\mathbf{s}_i, t_i) - \bar{Z}] [Z(\mathbf{s}_j, t_j) - \bar{Z}]$$

donde $N(\mathbf{s}, u) = \{[(\mathbf{s}_i, t_i), (\mathbf{s}_j, t_j)] : \mathbf{s}_i - \mathbf{s}_j = \mathbf{h}, t_i - t_j = u\}$ considerando una tolerancia del mismo modo que en el caso espacial.

Librerías de R

```
library("sp")
library("spacetime")
library("ggplot2")
library("dplyr")
library("gstat")
library("RColorBrewer")
```

```
library("STRbook")
library("tidyr")
library("grid")
library("gridExtra")
```

Formato de la Base datos para gstat

```
data(wind)      # base de datos del viento
head(wind)
```

```
##   year month day  RPT  VAL  ROS  KIL  SHA  BIR  DUB  CLA  MUL  CLO
## 1   61     1   1 15.04 14.96 13.17  9.29 13.96  9.87 13.67 10.25 10.83 12.58
## 2   61     1   2 14.71 16.88 10.83  6.50 12.62  7.67 11.50 10.04  9.79  9.67
## 3   61     1   3 18.50 16.88 12.33 10.13 11.17  6.17 11.25  8.04  8.50  7.67
## 4   61     1   4 10.58  6.63 11.75  4.58  4.54  2.88  8.63  1.79  5.83  5.88
## 5   61     1   5 13.33 13.25 11.42  6.17 10.71  8.21 11.92  6.54 10.92 10.34
## 6   61     1   6 13.21  8.12  9.96  6.67  5.37  4.50 10.67  4.42  7.17  7.50
##      BEL  MAL
## 1 18.50 15.04
## 2 17.54 13.83
## 3 12.75 12.71
## 4  5.46 10.88
## 5 12.92 11.83
## 6  8.12 13.17
```

```
class(wind)
```

```
## [1] "data.frame"
```

```
dim(wind)
```

```
## [1] 6574   15
```


```
wind[c(1,nrow(wind)),1:3]  # inicio-fin del periodo
```

```
##      year month day
## 1      61     1   1
## 6574   78    12  31
```

```
time_part = as.POSIXct(paste( paste0(19,wind[,1]), wind[,2], wind[,3], sep="-" ), tz = "GMT")
head(time_part)
```

```
## [1] "1961-01-01 GMT" "1961-01-02 GMT" "1961-01-03 GMT" "1961-01-04 GMT"
## [5] "1961-01-05 GMT" "1961-01-06 GMT"
```

```
coords = cbind(lat= -33-runif(12), lon= -70-runif(12))
plot(coords, pch=20)
```



```

spat_part = SpatialPoints(coords = coords)

# formato STFDF
dfST <- STFDF(sp = spat_part,
              time = time_part,
              data = data.frame(wind=c(t(wind[,-(1:3)])))) )

proj4string(dfST) <- CRS("+proj=longlat +ellps=WGS84")
class(dfST)

```

```

## [1] "STFDF"
## attr(,"package")
## [1] "spacetime"

```

Kriging Espacio Temporal

Kriging universal espacio-temporal permite realizar predicciones cuando la media se modela linealmente y la covarianza viene dada por un proceso estacionario. Para realizar el ajuste del semivariograma y posterior predicción se utilizará la librería *gstat*. Nos centramos en los datos de temperatura máxima del conjunto de datos de la NOAA (Tmax) en julio de 1993, disponible en la librería *TSRBook*.

Base de datos para análisis

```
data("STObj3", package = "STRbook")      # Datos ya preparados en STRbook
STObj4 <- STObj3[, "1993-07-01::1993-07-31"] # Se considera una parte de la Data
class(STObj4)
```

```
## [1] "STFDF"
## attr(,"package")
## [1] "spacetime"
```

```
head(STObj4@data, 10)      # El formato STFDF, requiere todos los campos
```

```
##      julian year month day   id  z
## 1  728111 1993     7    1 3804 82
## 2  728111 1993     7    1 3809 NA
## 3  728111 1993     7    1 3810 93
## 4  728111 1993     7    1 3811 91
## 5  728111 1993     7    1 3812 90
## 6  728111 1993     7    1 3813 95
## 7  728111 1993     7    1 3814 NA
## 8  728111 1993     7    1 3816 93
## 9  728111 1993     7    1 3817 NA
## 10 728111 1993     7    1 3820 96
```

```
head(STObj4@sp)      # coordenadas espaciales
```

```
## SpatialPoints:
##      lon      lat
## 1 -81.43333 39.35000
## 2 -89.40000 36.01667
## 3 -81.38333 35.73333
## 4 -88.91666 35.60000
## 5 -82.48333 35.43333
## 6 -83.65000 32.70000
## Coordinate Reference System (CRS) arguments: +proj=longlat +ellps=WGS84
```

```
head(STObj4@time)      # coordenadas temporales
```

```
##      timeIndex
## 1993-07-01    1278
## 1993-07-02    1279
## 1993-07-03    1280
## 1993-07-04    1281
## 1993-07-05    1282
## 1993-07-06    1283
```


```
summary(STObj4)
```

```
## Object of class STFDF
## with Dimensions (s, t, attr): (328, 31, 6)
## [[Spatial:]]
## Object of class SpatialPoints
## Coordinates:
##      min      max
## lon -99.96667 -80.00000
## lat  32.01667  45.86666
## Is projected: FALSE
## proj4string : [+proj=longlat +ellps=WGS84]
## Number of points: 328
## [[Temporal:]]
##      Index      timeIndex
## Min.   :1993-07-01   Min.   :1278
## 1st Qu.:1993-07-08   1st Qu.:1286
## Median :1993-07-16   Median :1293
## Mean   :1993-07-16   Mean   :1293
## 3rd Qu.:1993-07-23   3rd Qu.:1300
## Max.   :1993-07-31   Max.   :1308
## [[Data attributes:]]
##      julian      year      month      day      id
## Min.   :728111   Min.   :1993   Min.   :7    Min.   : 1    Min.   : 3804
## 1st Qu.:728118   1st Qu.:1993   1st Qu.:7    1st Qu.: 8    1st Qu.:13879
## Median :728126   Median :1993   Median :7    Median :16    Median :14820
## Mean   :728126   Mean   :1993   Mean   :7    Mean   :16    Mean   :31856
## 3rd Qu.:728134   3rd Qu.:1993   3rd Qu.:7    3rd Qu.:24    3rd Qu.:14992
## Max.   :728141   Max.   :1993   Max.   :7    Max.   :31    Max.   :94930
##
##      z
## Min.   : 61.00
## 1st Qu.: 83.00
## Median : 89.00
## Mean   : 88.55
## 3rd Qu.: 95.00
## Max.   :106.00
## NA's   :6046
```

Análisis Descriptivo

Para explorar que la dependencia espacio-temporal es relevante debemos calcular el variograma empírico

```
vv <- variogram(object = z ~ 1 + lat, # componente del efecto fijo
               data = STObj4,        # data
               width = 80,           # bin espacial (80 km)
               cutoff = 1000,        # considerar pts < 1000 km de distancia
               tlags = 0.01:6.01)    # 0 días a 6 días
plot(vv)
```



Modelos de Covarianza Paramétricos

Si $\{Z(\mathbf{s}, t)\}$ es un proceso espacio-temporal con función de covarianza, $C(\mathbf{h}, u; \boldsymbol{\theta})$, parametrizada por $\boldsymbol{\theta}$. Estos modelos parametrizados se diferencian en no-separables y separables.

Modelos Separables

Sean $\rho_S(\mathbf{h}; \theta_1)$ y $\rho_T(u)$ funciones de correlación válidas en el espacio y tiempo, respectivamente, luego una función de correlación válida en el espacio-tiempo es

$$\rho_{ST}(\mathbf{h}, u) = \rho_S(\mathbf{h})\rho_T(u) \quad \wedge \quad \rho_{ST}(\mathbf{h}, u) = \rho_S(\mathbf{h}) + \rho_T(u)$$

Por ejemplo, un modelo de covarianza válido es

$$C(\mathbf{h}, u; \boldsymbol{\theta}) = \sigma^2 e^{-\|\mathbf{h}\|/\phi_s} e^{-|u|/\phi_t} \quad (\text{Doble Exponencial})$$

Modelos No-Separables

En este caso, la estructura de correlación $\rho_{ST}(\mathbf{h}, u)$ no se puede factorizar por el espacio y tiempo. Luego, algunos modelos de covarianza válidos son

$$C(\mathbf{h}, u; \boldsymbol{\theta}) = \frac{\sigma^2}{(|u|^{2\gamma} + 1)^\nu} \exp \left\{ \frac{-c\|\mathbf{h}\|^{2\gamma}}{(|u|^{2\gamma} + 1)^{\beta\gamma}} \right\} \quad (\text{Gneiting})$$

Un modelo general, corresponde a

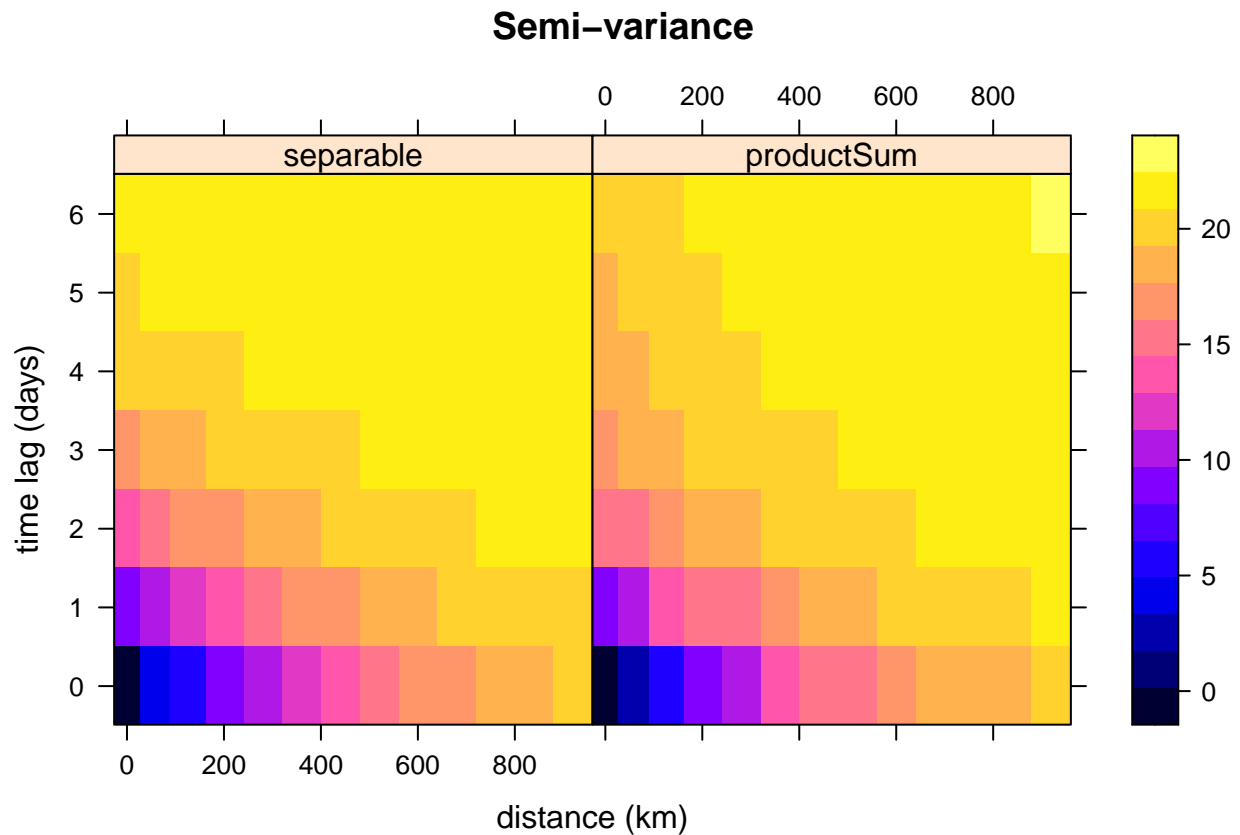
$$C(\mathbf{h}, u; \boldsymbol{\theta}) = pC_1^S(\mathbf{h})C_1^T(u) + qC_2^S(\mathbf{h}) + rC_2^T(u) \quad (\text{Suma-Producto})$$

Ajuste de Modelos de Covarianza

```
## Modelo Separable
sepVgm <- vgmST(stModel = "separable",
               space = vgm(10, "Exp", 400, nugget = 0.1),
               time = vgm(10, "Exp", 1, nugget = 0.1),
               sill = 20)
sepVgm <- fit.StVariogram(vv, sepVgm)

## Modelos No-Separable
sumprodVgm <- vgmST(stModel = "productSum",
                   space = vgm(10, "Exp", 400, nugget = 0.1),
                   time = vgm(10, "Exp", 1, nugget = 0.1),
                   k=15)
sumprodVgm <- fit.StVariogram(vv, sumprodVgm)

## Grafica de ambos variogramas
plot(vv, list(sepVgm, sumprodVgm), main = "Semi-variance")
```



Predicción

Considere el modelo

$$\mathbf{Z} = \mathbf{Y} + \boldsymbol{\epsilon} \quad \wedge \quad \mathbf{Y} = \boldsymbol{\mu} + \boldsymbol{\eta}$$

donde $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$. Notar que

$$\text{cov}(\mathbf{Y}) = \mathbf{C}_y = \mathbf{C}_\eta; \quad \text{cov}(\boldsymbol{\epsilon}) = \mathbf{C}_\epsilon; \quad \wedge \quad \text{cov}(\mathbf{Z}) = \mathbf{C}_z = \mathbf{C}_y + \mathbf{C}_\eta$$

Sea \mathbf{s}_0, t_0 donde se requiere hacer la predicción y donde se tiene $\mathbf{x}_0 = \mathbf{x}(\mathbf{s}_0, t_0)$. Definiendo,

$$\mathbf{c}_0^\top = \text{cov}(Y(\mathbf{s}_0, t_0), \mathbf{Z}) \quad \wedge \quad c_{0,0} = \mathbb{V}(Y(\mathbf{s}_0, t_0)).$$

Asumiendo que se tiene la distribución Gaussiana conjunta, se tiene

$$Y(\mathbf{s}_0, t_0) \mid \mathbf{Z} \mathcal{N}(\mathbf{x}_0^\top \boldsymbol{\beta} + \mathbf{c}_0^\top \mathbf{C}_z^{-1}(\mathbf{Z} - \mathbf{X}\boldsymbol{\beta}); c_{0,0} - \mathbf{c}_0^\top \mathbf{C}_z^{-1} \mathbf{c}_0)$$

Los cuales corresponden al predictor Kriging simple, es decir,

$$\hat{Y}(\mathbf{s}_0, t_0) = \mathbf{x}_0^\top \boldsymbol{\beta} + \mathbf{c}_0^\top \mathbf{C}_z^{-1}(\mathbf{Z} - \mathbf{X}\boldsymbol{\beta}) \quad \wedge \quad \sigma_{sk}^2(\mathbf{s}_0, t_0) = c_{0,0} - \mathbf{c}_0^\top \mathbf{C}_z^{-1} \mathbf{c}_0$$

En el caso que $\boldsymbol{\beta}$ sea desconocido (el caso más habitual) se tienen las ecuación de kriging universal

$$\hat{Y}(\mathbf{s}_0, t_0) = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} + \mathbf{c}_0^\top \mathbf{C}_z^{-1}(\mathbf{Z} - \mathbf{X}\hat{\boldsymbol{\beta}}) \quad \wedge \quad \sigma_{sk}^2(\mathbf{s}_0, t_0) = c_{0,0} - \mathbf{c}_0^\top \mathbf{C}_z^{-1} \mathbf{c}_0 + k$$

donde

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= (\mathbf{X}^\top \mathbf{C}_z^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{C}_z^{-1} \mathbf{Z} \\ k &= (\mathbf{x}_0 - \mathbf{X}^\top \mathbf{C}_z^{-1} \mathbf{c}_0)^\top (\mathbf{X}^\top \mathbf{C}_z^{-1} \mathbf{X})^{-1} (\mathbf{x}_0 - \mathbf{X}^\top \mathbf{C}_z^{-1} \mathbf{c}_0) \end{aligned}$$

Grilla de predicción

En primer lugar se remueven los datos donde no hay observaciones y se define la paleta de colores:


```
## -----
STObj5 <- as(STObj4[, -14], "STIDF")          # convert to STIDF
STObj5 <- subset(STObj5, !is.na(STObj5$z))    # remove missing data
head(STObj5@data)

##      julian year month day   id  z
## 1 728111 1993      7   1 3804 82
## 3 728111 1993      7   1 3810 93
## 4 728111 1993      7   1 3811 91
## 5 728111 1993      7   1 3812 90
## 6 728111 1993      7   1 3813 95
## 8 728111 1993      7   1 3816 93

## -----
color_pal <- rev(colorRampPalette(brewer.pal(11, "Spectral"))(16))
```

Ahora se procede a definir la grilla de predicción


```
## parte espacial
spat_pred_grid <- expand.grid(
  lon = seq(-100, -80, length = 20),
  lat = seq(32, 46, length = 20)) %>%
  SpatialPoints(proj4string = CRS(proj4string(STObj3)))
gridded(spat_pred_grid) <- TRUE
plot(spat_pred_grid)
```



```
## parte temporal
temp_pred_grid <- as.Date("1993-07-01") + seq(3, 28, length = 6)
temp_pred_grid
```

```
## [1] "1993-07-04" "1993-07-09" "1993-07-14" "1993-07-19" "1993-07-24"
## [6] "1993-07-29"
```

```
## Formato para la grilla de predicción
DE_pred <- STF(sp = spat_pred_grid, # spatial part
              time = temp_pred_grid) # temporal part
head(DE_pred@sp)
```

```
## Object of class SpatialPixels
## Grid topology:
##   cellcentre.offset  cellsize cells.dim
## lon                -100 1.0526316      20
```

```
## lat          32 0.7368421      20
## SpatialPoints:
##           lon lat
## [1,] -100.00000 32
## [2,]  -98.94737 32
## [3,]  -97.89474 32
## [4,]  -96.84211 32
## [5,]  -95.78947 32
## [6,]  -94.73684 32
## Coordinate Reference System (CRS) arguments: +proj=longlat +ellps=WGS84
## +no_defs
```

```
head(DE_pred@time)
```

```
##           timeIndex
## 1993-07-04         1
## 1993-07-09         2
## 1993-07-14         3
## 1993-07-19         4
## 1993-07-24         5
## 1993-07-29         6
```

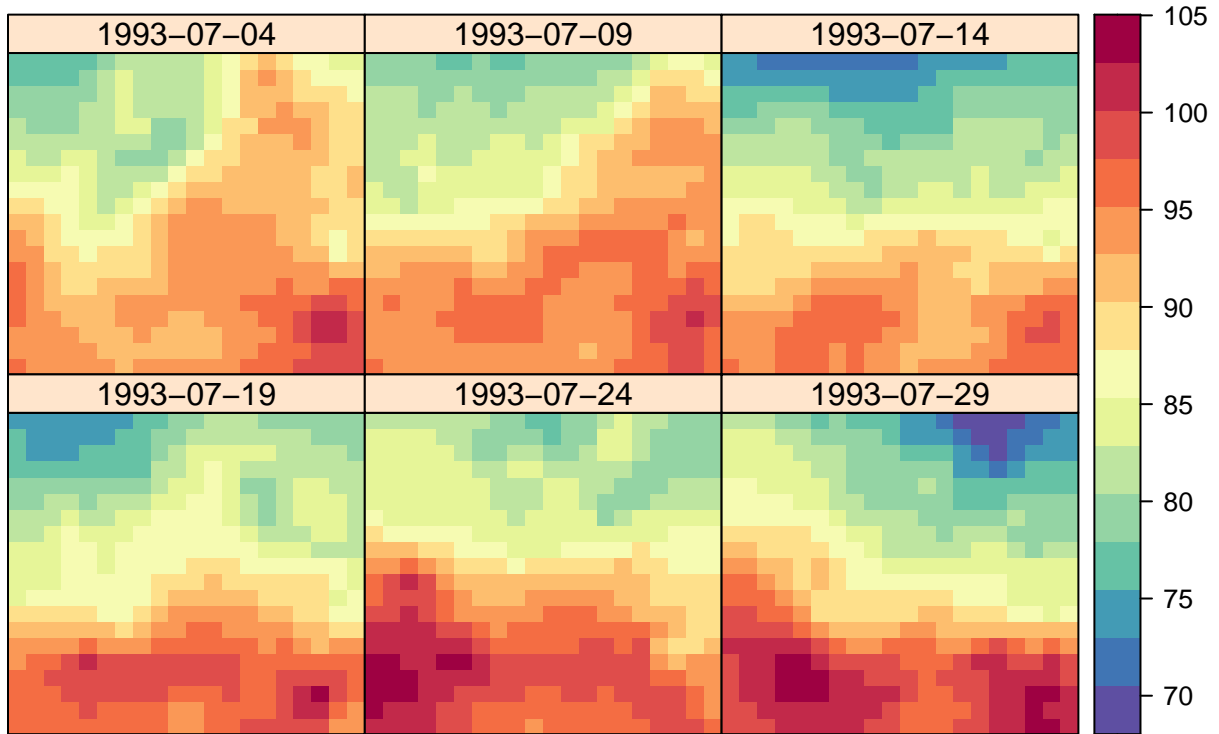
Predicción mediante el modelo separable

Para realizar la predicción mediante kriging universal con media lineal y función de covarianza separable se debe usar *krigeST*:

```
## -----
pred_kriged <- krigeST(z ~ 1 + lat,          # latitude trend
                      data = STObj5,        # data set w/o 14 July
                      newdata = DE_pred,    # prediction grid
                      modelList = sepVgm,   # semivariogram
                      computeVar = TRUE)    # compute variances
## -----

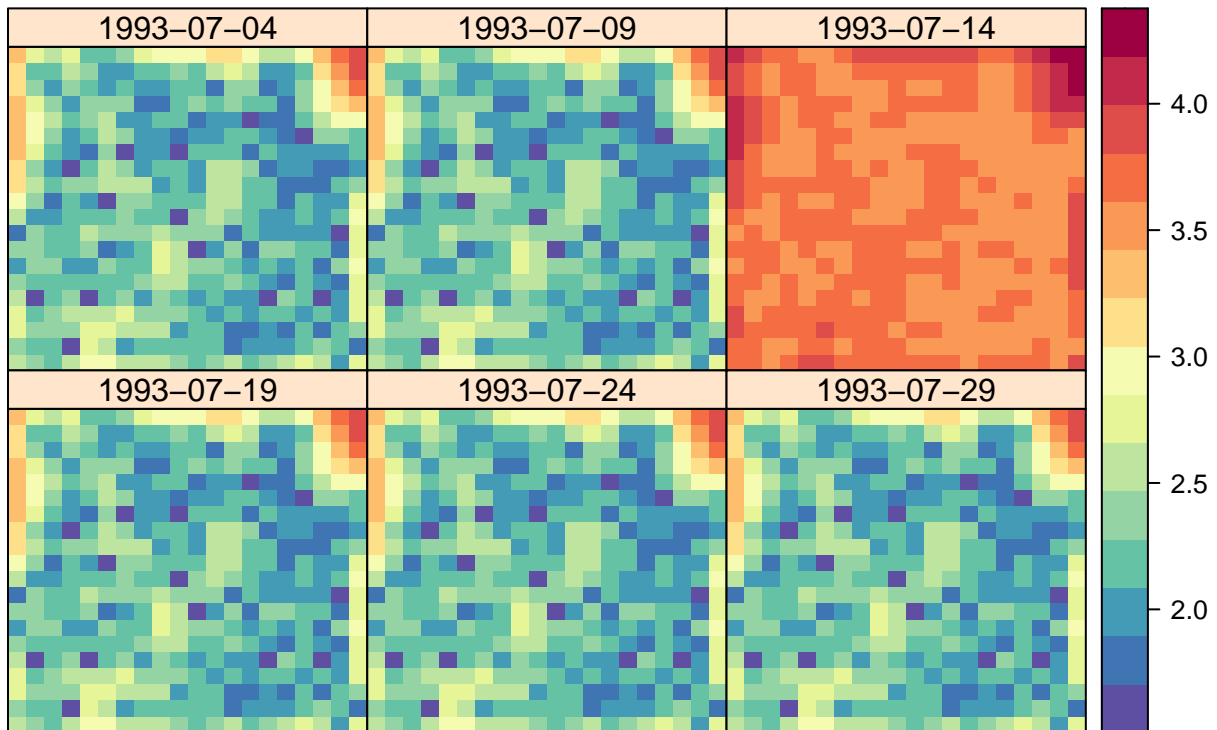
stplot(pred_kriged,
       main = "Predictions (degrees Fahrenheit)",
       layout = c(3, 2),
       col.regions = color_pal)
```

Predictions (degrees Fahrenheit)



```
## -----
pred_kriged$se <- sqrt(pred_kriged$var1.var)
stplot(pred_kriged[, , "se"],
       main = "Prediction std. errors (degrees Fahrenheit)",
       layout = c(3, 2),
       col.regions = color_pal)
```

Prediction std. errors (degrees Fahrenheit)



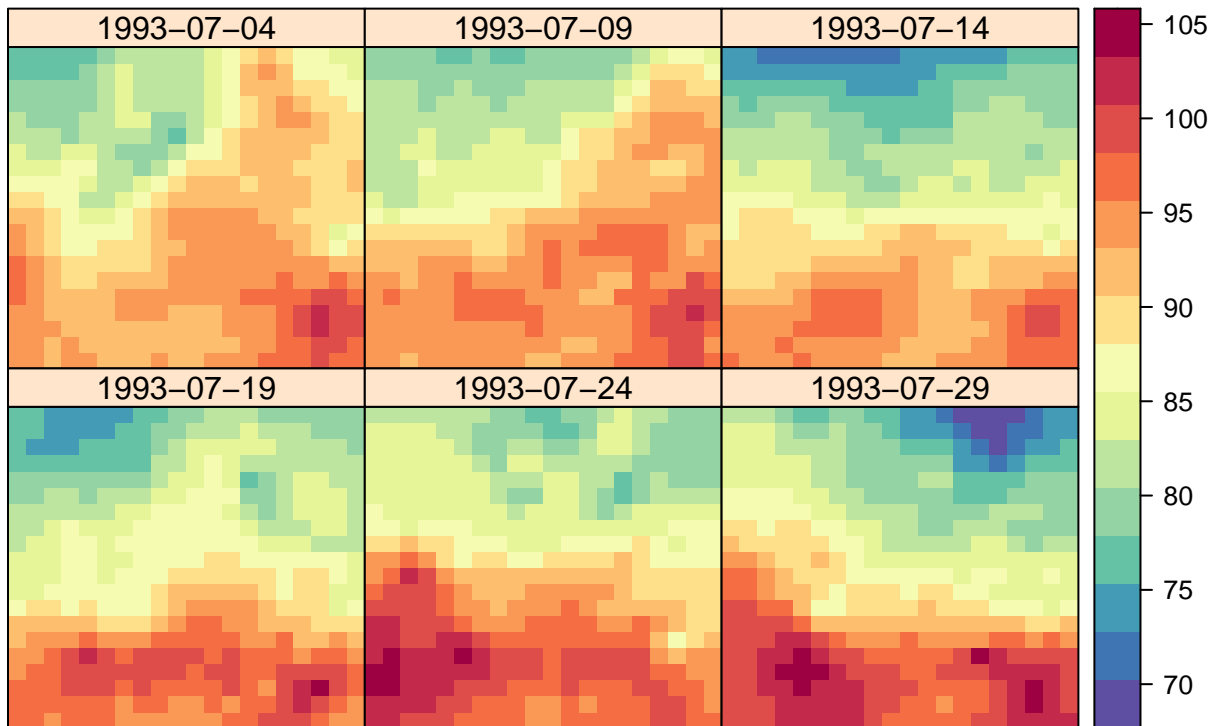
Predicción mediante el modelo sum-product

Para realizar la predicción mediante kriging universal con media lineal y función de covarianza no-separable dada por la estructura sum-product, también se debe usar *krigeST*, solo cambia el modelo de variograma:

```
## -----
pred_kriged2 <- krigeST(z ~ 1 + lat,          # latitude trend
                        data = STObj5,        # data set w/o 14 July
                        newdata = DE_pred,    # prediction grid
                        modelList = sumprodVgm, # semivariogram
                        computeVar = TRUE)     # compute variances

## -----
stplot(pred_kriged2,
        main = "Predictions (degrees Fahrenheit)",
        layout = c(3, 2),
        col.regions = color_pal)
```

Predictions (degrees Fahrenheit)



```
## -----
pred_kriged2$se <- sqrt(pred_kriged2$var1.var)
stplot(pred_kriged2[, , "se"],
       main = "Prediction std. errors (degrees Fahrenheit)",
       layout = c(3, 2),
       col.regions = color_pal)
```

Prediction std. errors (degrees Fahrenheit)

